Ecole Centrale de Casablanca (ECC)

Introduction aux techniques d'Apprentissage Automatique

(Machine Learning)

Prof. Y. Lamrani Alaoui
lamrani@emi.ac.ma
EMI-Rabat

Centrale
CASABLANCA



Plan de cours

1. **Introduction et notions de base**
   - Panorama des paradigmes d'apprentissage
2. **Apprentissage supervisé**
   - Régression, dont régression régularisée (Ridge, Lasso, Elastic Net)
   - Classification binaire et multi-classes
   - Évaluation et optimisation des hyperparamètres
3. **Apprentissage non supervisé**
   - Réduction de dimension
   - Clustering : partition, hiérarchique, densité, modèles probabilistes
   - Détection d'anomalies
4. **Apprentissage semi-supervisé et par renforcement**
   - Hypothèses du semi-supervisé et pseudo-étiquetage
   - Renforcement : valeur, politique, acteur–critique, applications
5. **Traitement du langage naturel (NLP)**
   - Représentation du texte et tâches classiques du NLP
6. **Introduction à l'IA générative**
   - LLM : pré-entraînement, SFT, RLHF, prompt engineering
   - Systèmes RAG et IA agentique

Apprentissage supervisé: Cas des données temporelles

Préparation des données temporelles

t	valeur
1	x_1
2	x_2
3	x_3
4	x_4
…	
T	x_T

Valeur plus récente

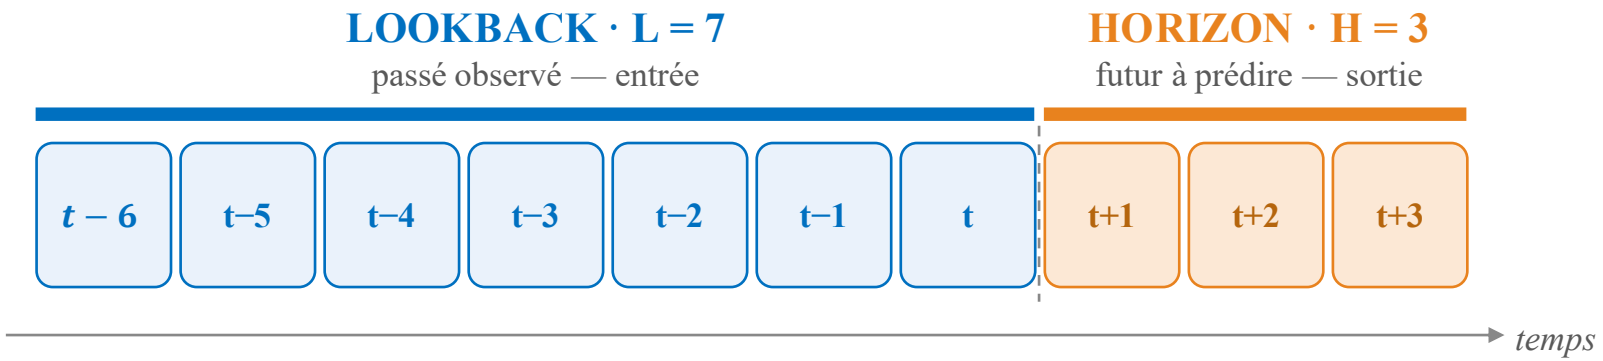
Principe de fenêtre glissante: consiste à utiliser les k observations précédentes pour prédire la suivante. Par exemple avec une fenêtre de taille 3



y_t	x_{t-1}	x_{t-2}	x_{t-3}
x_4	x_3	x_2	x_1
x_5	x_4	x_3	x_2
x_6	x_5	x_4	x_3
…			
x_T	x_{T-1}	x_{T-2}	x_{T-3}

Préparation des données temporelles
(Lookback et Forecast Horizon)

On découpe la série temporelle en fenêtres : un passé observé (lookback) sert à prédire un futur (forecast horizon).



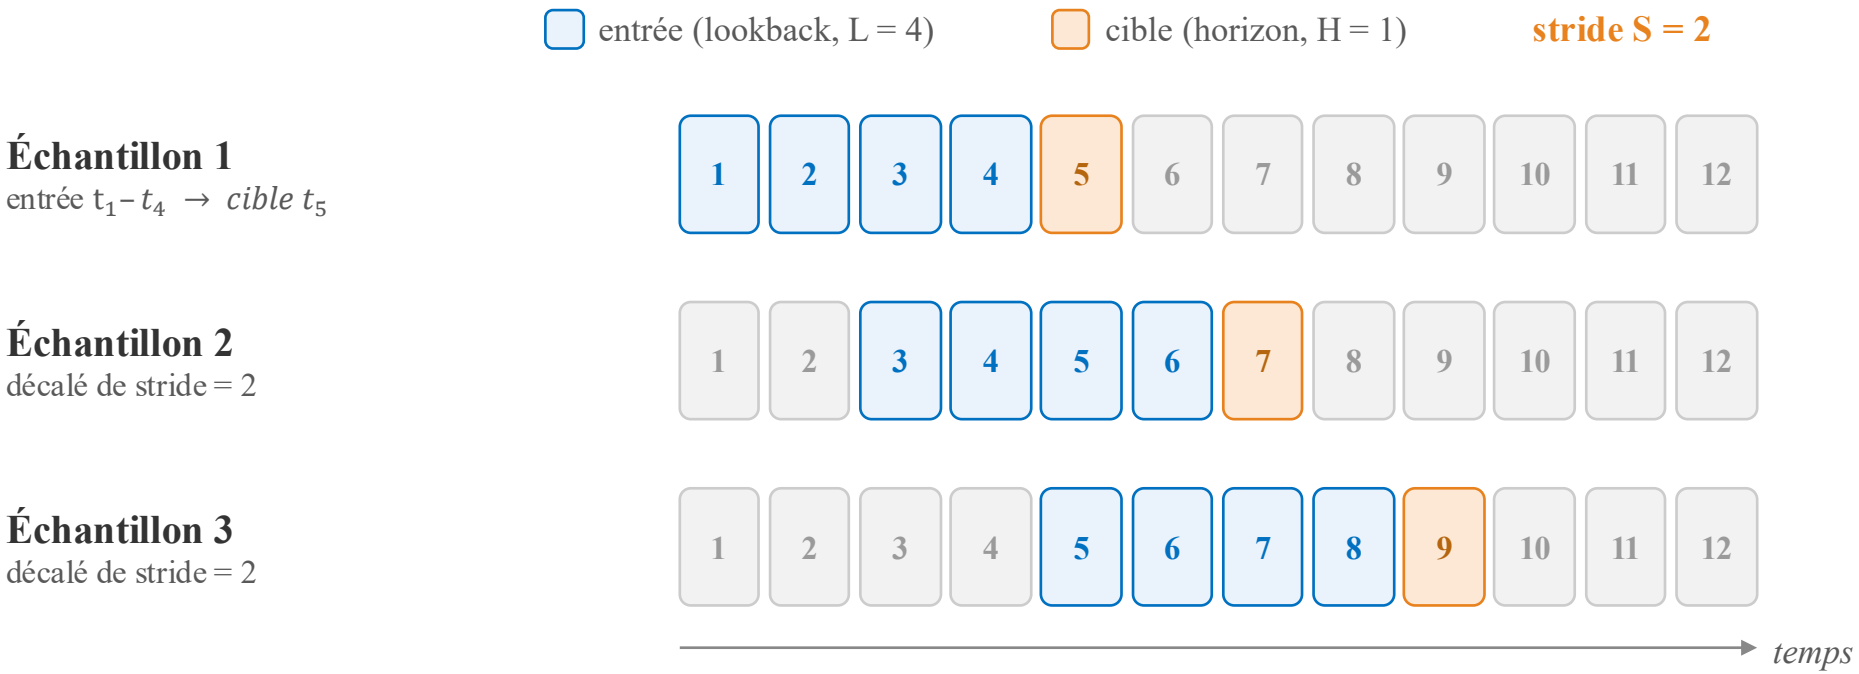
Exemple : prévoir la consommation électrique des 3 prochaines heures (H = 3) à partir des 7 dernières heures observées (L = 7).

Multi-step · prédit ŷ(t+1) … ŷ(t+H)
toute la séquence de l'horizon

Direct à H · prédit seulement ŷ(t+H), uniquement la dernière valeur

Préparation des données temporelles (Stride)

Le stride est le pas de décalage de la fenêtre entre deux échantillons successifs (entrée + cible).



Stride = 1 → fenêtres très chevauchantes (beaucoup d'échantillons). **Stride = L** → fenêtres disjointes (aucun chevauchement).

Préparation des données temporelles (Input size)

Input size = nombre de variables (features) mesurées à chaque pas de temps ; chaque vecteur x_t a pour dimension l'input size.

Univarié · input size = 1

$x_t =$ [prix]

Multivarié · input size = 3

$x_t =$ [Température ; Humidité ; Vent] — **3 features**

Terme	Définition	Exemple
Lookback (L)	Nombre de pas de temps passés utilisés en entrée	7 jours
Forecast horizon (H)	Nombre de pas de temps futurs à prédire	3 jours
Input size	Nombre de features (variables) par pas de temps	3 (temp., hum., vent)
Stride (S)	Décalage de la fenêtre entre deux échantillons	2

Tester la capacité prédictive d'un modèle de séries chronologiques

(Evaluation par train/test split: *Hold-Out temporel*)

- Une façon de tester la performance d'un modèle de séries chronologiques est de répartir la série en une partie d'apprentissage et une partie test avec un ordre chronologique.
- Le modèle est à entrainer avec la partie d'apprentissage et à tester avec la partie test.



Tester la capacité prédictive d'un modèle
(Evaluation par train/test split: *Hold-Out temporel*)

Des exemples de mesures de performance à utiliser sont données comme suit :

- Mean Squared Error (MSE): $MSE = \frac{1}{h}\sum e_k^2$ avec $e_k = Y_k - \hat{Y}_k$
- Root Mean Squared Error (MSE): $RMSE = \sqrt{\frac{1}{h}\sum\left(Y_t - \hat{Y}_t\right)^2}$
- Mean Absolute Error (MAE): $MAE = \sum \frac{|Y_t - \hat{Y}_t|}{h}$
- Mean Absolute Percentage Error (MAPE): $MAPE = \frac{1}{h}\sum\left|\frac{Y_t - \hat{Y}_t}{Y_t}\right|$

Tester la capacité prédictive d'un modèle
(Evaluation par train/test split: *Hold-Out temporel*)

Des exemples de mesures de performance à utiliser sont données comme suit :

- Mean Squared Error (MSE): $MSE = \frac{1}{h}\sum e_k^2$ avec $e_k = Y_k - \hat{Y}_k$
- Root Mean Squared Error (MSE): $RMSE = \sqrt{\frac{1}{h}\sum\left(Y_t - \hat{Y}_t\right)^2}$
- Mean Absolute Error (MAE): $MAE = \sum \frac{|Y_t - \hat{Y}_t|}{h}$
- Mean Absolute Percentage Error (MAPE): $MAPE = \frac{1}{h}\sum\left|\frac{Y_t - \hat{Y}_t}{Y_t}\right|$

Tester la capacité prédictive d'un modèle par cross validation temporelle

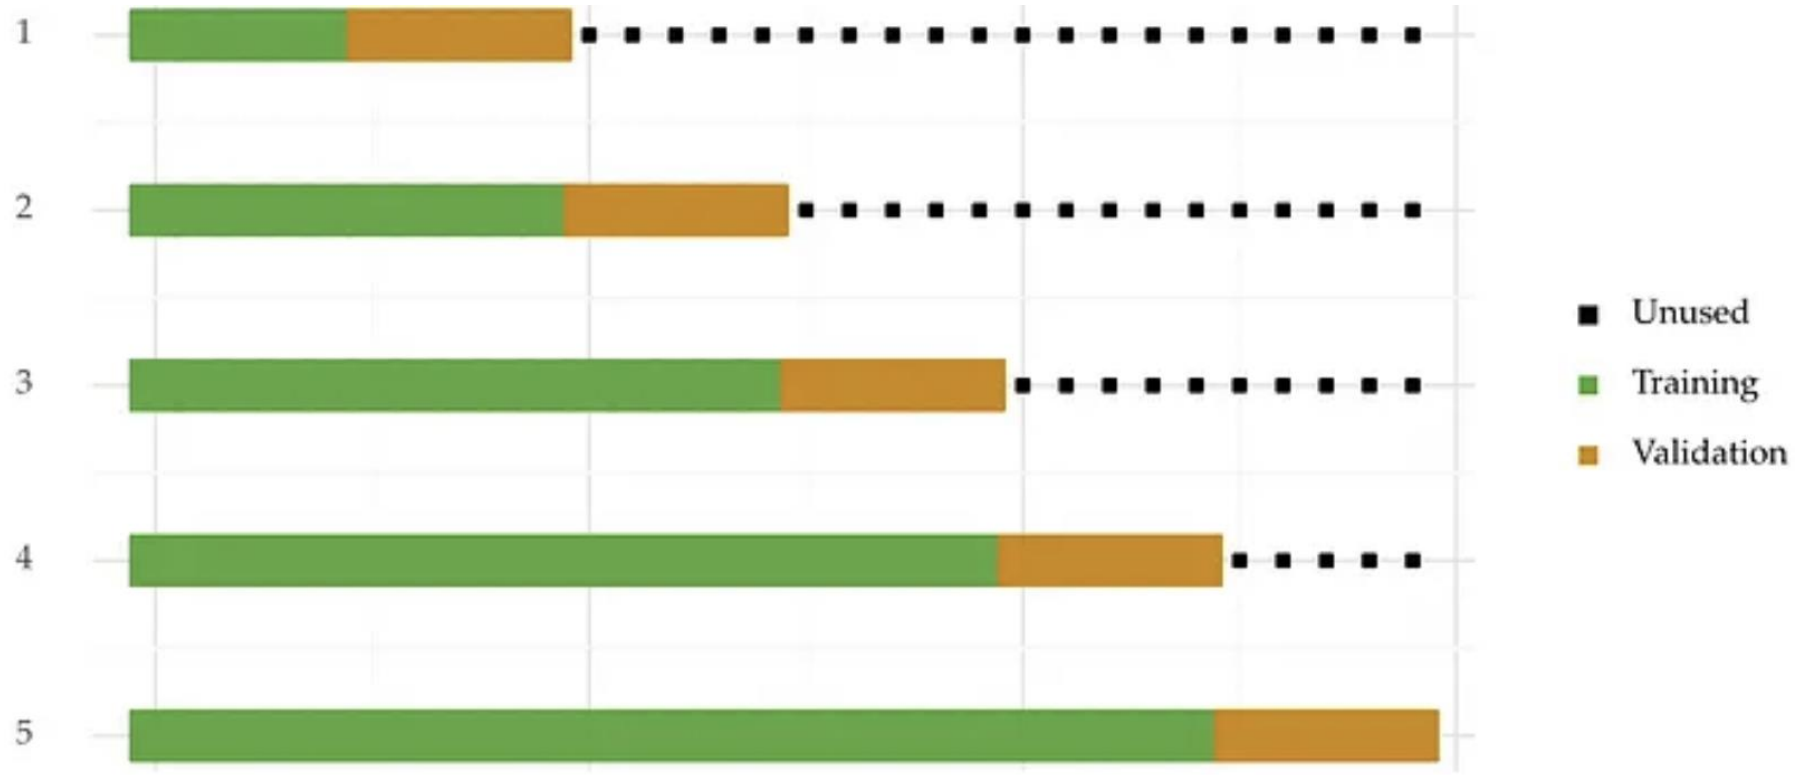
la validation croisée temporelle consiste à répéter plusieurs fois l'opération d'apprentissage et de prévision tout en respectant systématiquement la chronologie des données.

On distingue souvent deux variantes :

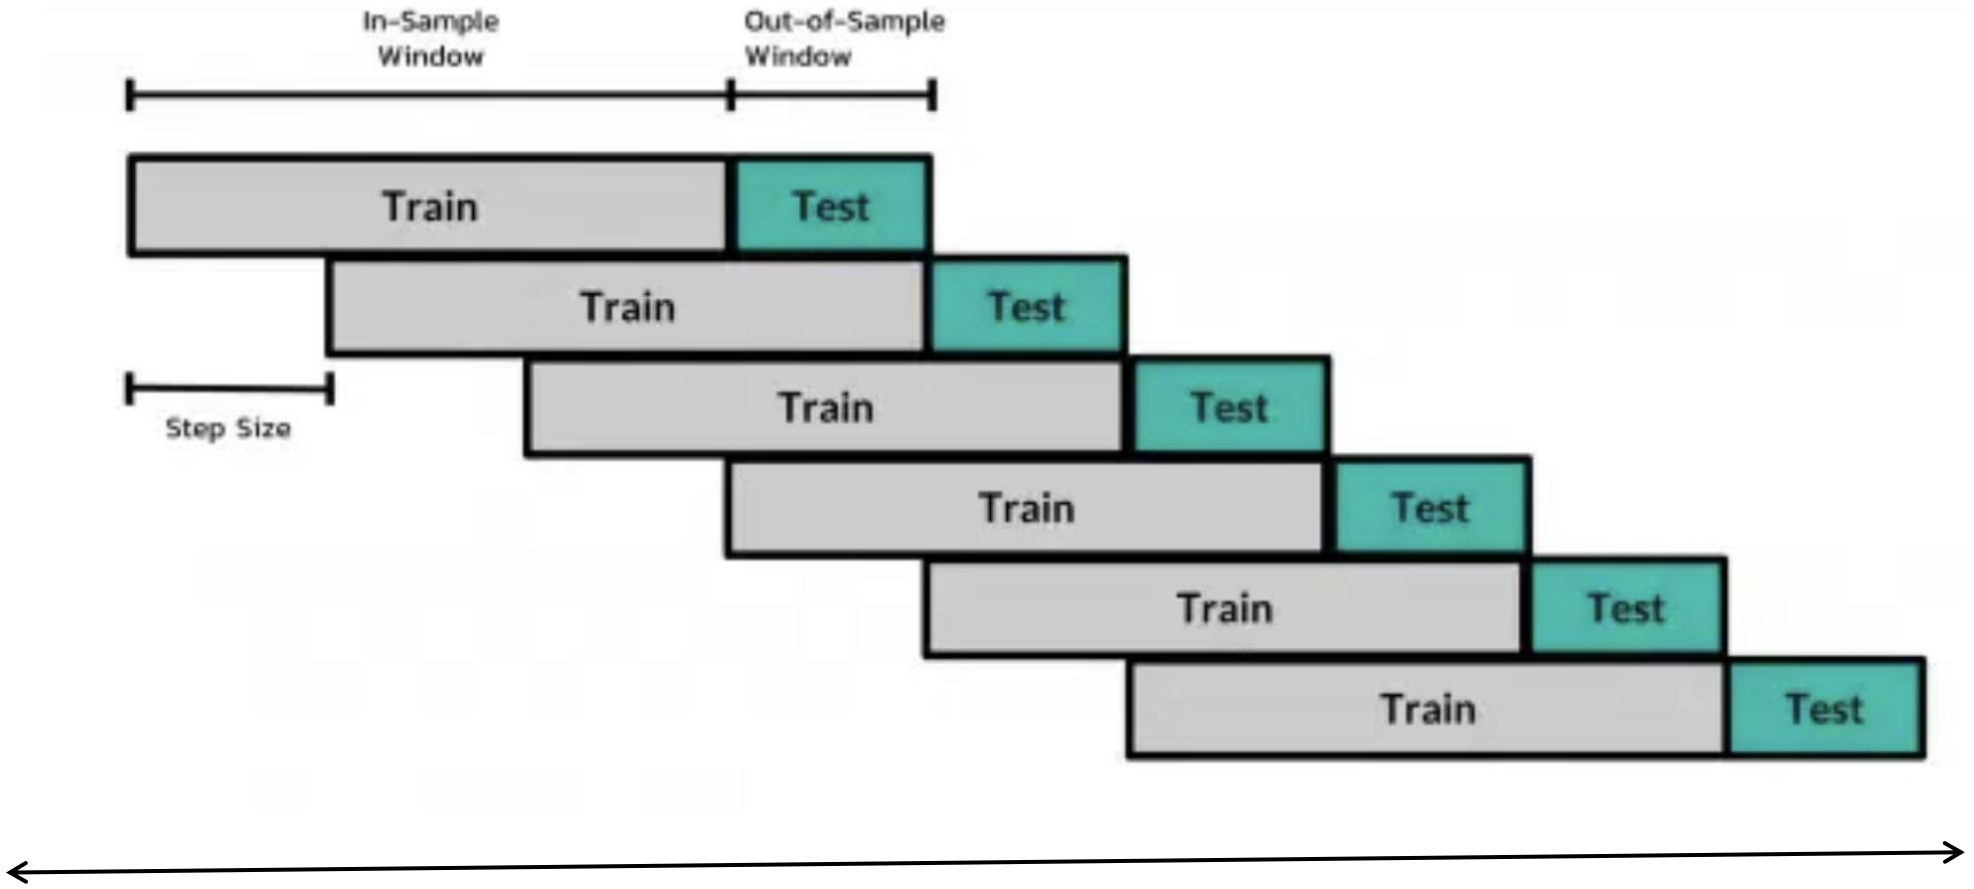
- **la validation croisée expansive** (*expanding window*) : la fenêtre d'apprentissage s'agrandit progressivement au fil du temps ;
- **la validation croisée glissante** (*sliding window*) : la taille de la fenêtre d'apprentissage reste fixe et se déplace progressivement dans le temps.

Tester la capacité prédictive d'un modèle

(*Expanding Window*)



Tester la capacité prédictive d'un modèle (*Rolling Window*)



Tester la capacité prédictive d'un modèle (Comparaison des 3 approches d'évaluation)

- Si les évaluations des trois approches sont proches, le modèle est plutôt stable
- Si l'erreur de train/test est plus faible que ceux de cross-validation, cela suggère que le split unique était trop **optimiste**
- Si $Perf_{sliding} > Perf_{expanding}$ alors, les données anciennes semblent dégrader la prévision, une mémoire courte est meilleure
- Si $Perf_{sliding} < Perf_{expanding}$, alors l'historique apporte de l'information utile

Comparer la capacité prédictive de deux modèles de prévision:
(test de Diebold Mariano (DM test)

Le test de **Diebold-Mariano** (1995), est un test statistique permettant de **comparer la capacité prédictive de deux modèles de prévision concurrents**.

Soit $\{y_t\}_{t=1}^{T}$ la série temporelle d'intérêt, et soient :

- $\hat{y}_{1,t}$: prévisions du **modèle 1**
- $\hat{y}_{2,t}$: prévisions du **modèle 2**

Les erreurs de prévision associées sont : $e_{i,t} = y_t - \hat{y}_{i,t}, i \in \{1,2\}$

- On définit le **différentiel de perte** : $d_t = L(e_{1,t}) - L(e_{2,t})$
- L'idée centrale est la suivante : si les deux modèles ont la même précision prédictive, alors $\mathbb{E}[d_t] = 0$.

Comparer la capacité prédictive de deux modèles de prévision:

(test de Diebold Mariano (DM test)

Hypothèse de test: $\begin{cases} H_0 : \mathbb{E}[d_t] = 0 \\ H_1 : \mathbb{E}[d_t] \neq 0 \end{cases}$

Soit $\bar{d} = \frac{1}{T}\sum_{t=1}^{T} d_t$ la moyenne empirique du différentiel. Sous l'hypothèse de stationnarité de $\{d_t\}$, Diebold et Mariano montrent que :

$$\mathrm{DM} = \frac{\bar{d}}{\sqrt{\widehat{\mathrm{Var}}(\bar{d})}} \xrightarrow{d} \mathcal{N}(0,1)$$

où la variance asymptotique est estimée par :

$$\widehat{\mathrm{Var}}(\bar{d}) = \frac{1}{T}\left(\hat{\gamma}_0 + 2\sum_{k=1}^{h-1}\hat{\gamma}_k\right)$$

avec $\hat{\gamma}_k$ l'autocovariance d'ordre k de d_t, et h l'horizon de prévision.

-Si $DM > 0$ et $p_{value} < \alpha$: le modèle 2 est meilleure

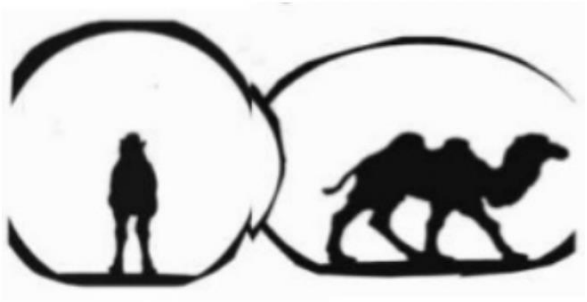
-Si $DM < 0$ et $p_{value} < \alpha$: le modèle 1 est meilleure

-Si $p_{value} > \alpha$, on ne rejette pas $\boldsymbol{H_0}$, les deux modèles sont statistiquement équivalents

Ecole Centrale de Casablanca (ECC)

Techniques de réduction de dimensions

(Analyse en Composantes Principales (ACP))

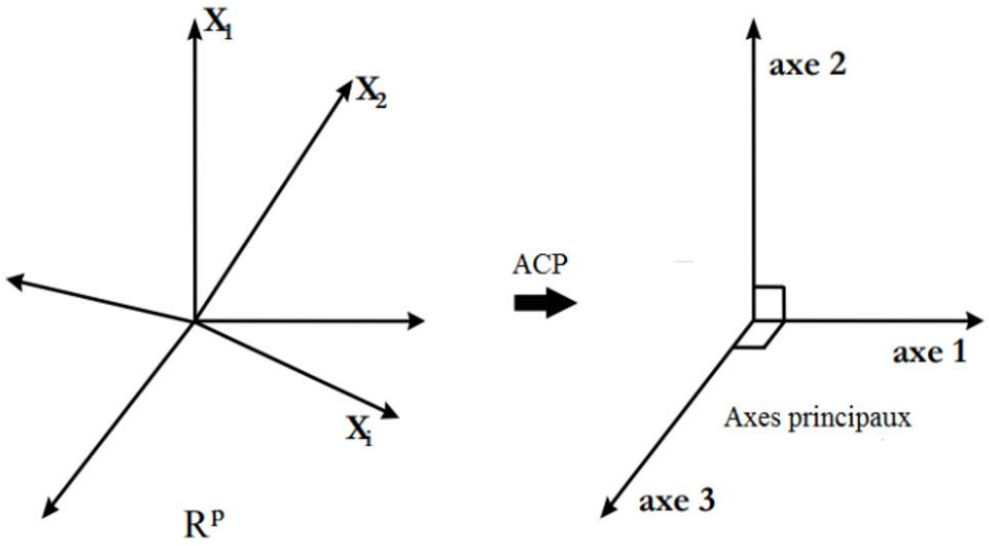


Prof. Y. Lamrani Alaoui
lamrani@emi.ac.ma
EMI-Rabat

Centrale
CASABLANCA

Introduction

- L'ACP est parmi les techniques de **réduction de dimension** les plus populaire
- L'objectif de l'ACP est de représenter un tableau de données (individus et variables) dans un espace de dimension inférieure à l'espace originel, tout en limitant la perte d'information.

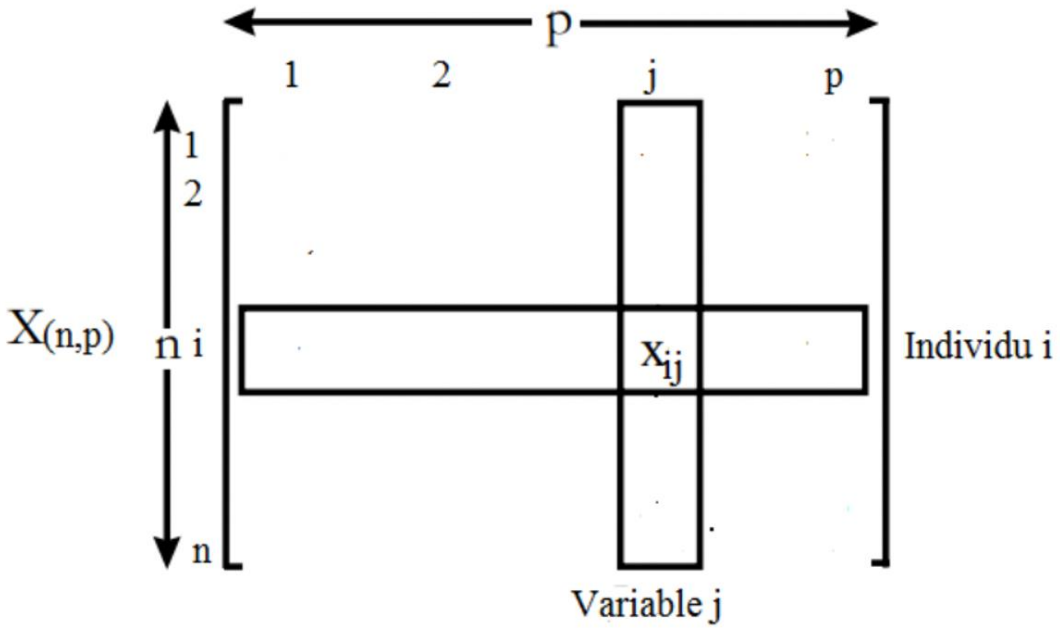


Introduction

- La représentation des données dans un espace de faible dimension peut faciliter considérablement l'analyse
- Les nouvelles variables sont appelées composantes principales (ou facteurs)
- Les axes qu'elles déterminent sont appelés axes principaux
- L'ACP cherche à:
  - Etudier les ressemblances et les différences entre les individus
  - Etudier les liaisons entre les variables

Données de l'ACP

- n individus observés sur p variables quantitatives, c'est-à-dire un nuage de n points dans un espace de p dimensions
  - Un individu et un élément de $\mathbb{R}^p$
  - Une variable est un élément de $\mathbb{R}^n$



Données de l'ACP

	Janv	Févr	Mars	Avri	Mai	Juin	juil	Août	Sept	Octo	Nove	Déce
Bordeaux	5.6	6.6	10.3	12.8	15.8	19.3	20.9	21.0	18.6	13.8	9.1	6.2
Brest	6.1	5.8	7.8	9.2	11.6	14.4	15.6	16.0	14.7	12.0	9.0	7.0
Clermont	2.6	3.7	7.5	10.3	13.8	17.3	19.4	19.1	16.2	11.2	6.6	3.6
Grenoble	1.5	3.2	7.7	10.6	14.5	17.8	20.1	19.5	16.7	11.4	6.5	2.3
Lille	2.4	2.9	6.0	8.9	12.4	15.3	17.1	17.1	14.7	10.4	6.1	3.5
Lyon	2.1	3.3	7.7	10.9	14.9	18.5	20.7	20.1	16.9	11.4	6.7	3.1
Marseille	5.5	6.6	10.0	13.0	16.8	20.8	23.3	22.8	19.9	15.0	10.2	6.9
Montpellier	5.6	6.7	9.9	12.8	16.2	20.1	22.7	22.3	19.3	14.6	10.0	6.5
Nantes	5.0	5.3	8.4	10.8	13.9	17.2	18.8	18.6	16.4	12.2	8.2	5.5
Nice	7.5	8.5	10.8	13.3	16.7	20.1	22.7	22.5	20.3	16.0	11.5	8.2
Paris	3.4	4.1	7.6	10.7	14.3	17.5	19.1	18.7	16.0	11.4	7.1	4.3
Rennes	4.8	5.3	7.9	10.1	13.1	16.2	17.9	17.8	15.7	11.6	7.8	5.4
Strasbourg	0.4	1.5	5.6	9.8	14.0	17.2	19.0	18.3	15.1	9.5	4.9	1.3
Toulouse	4.7	5.6	9.2	11.6	14.9	18.7	20.9	20.9	18.3	13.3	8.6	5.5
Vichy	2.4	3.4	7.1	9.9	13.6	17.1	19.3	18.8	16.0	11.0	6.6	3.4

Tableau. Exemple des données de l'ACP

Données de l'ACP

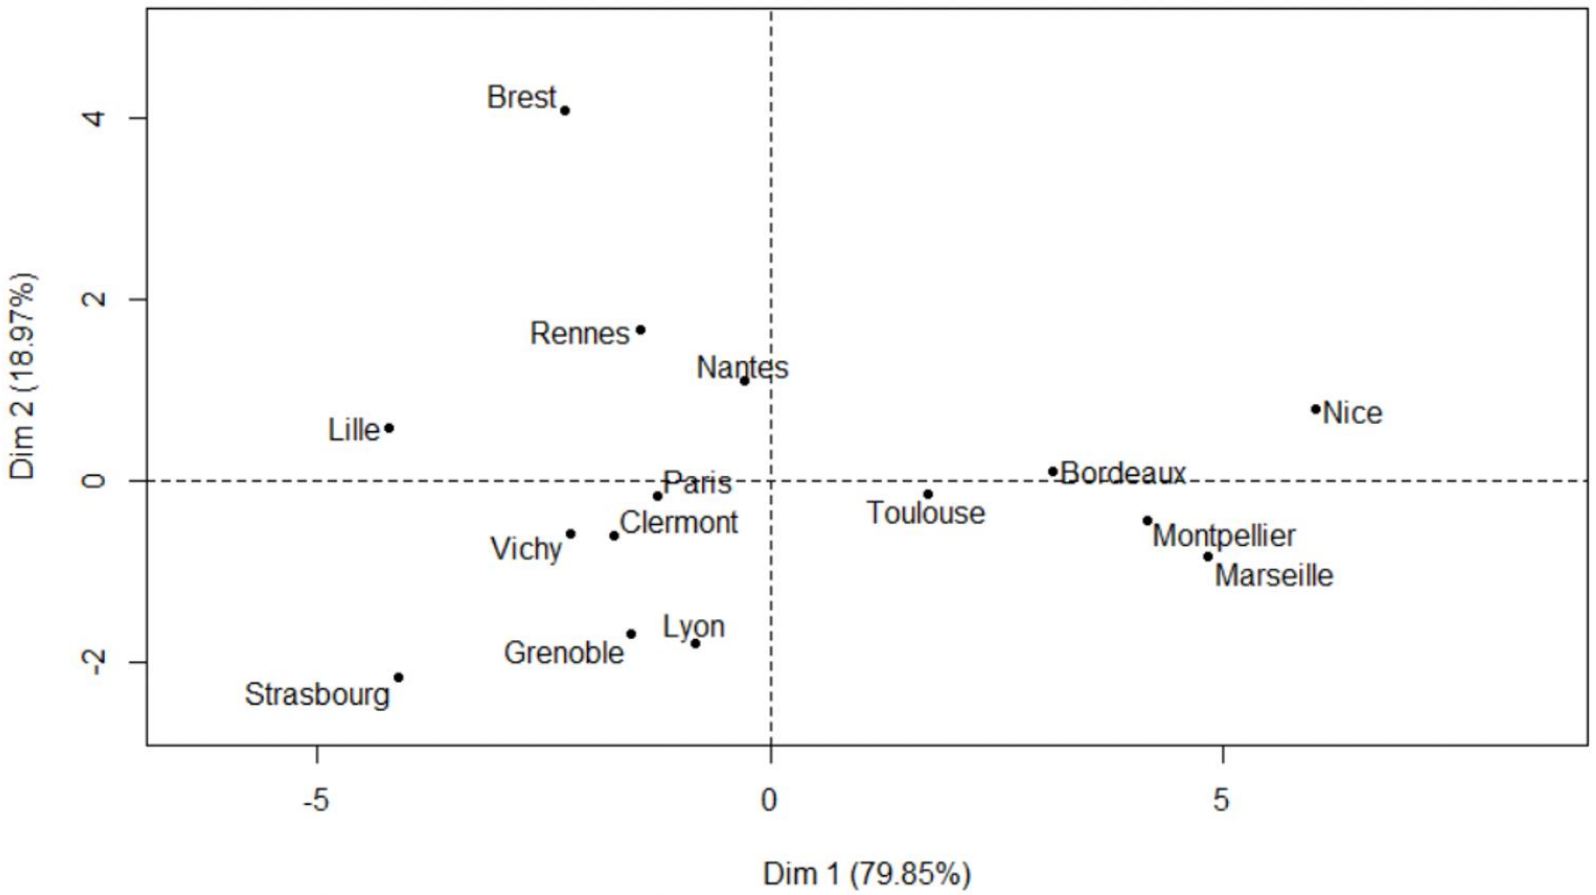


Fig. Représentation des données dans un nouvel espace de deux dimensions

Données de l'ACP

Pré-traitement des données:

Avant de lancer l'ACP, il est recommandé de centrer et de réduire les données.

- Le centrage des données(retrancher la moyenne) consiste en un changement d'origine, qui place la moyenne de la distribution au point 0. Le centrage ne modifie pas la structure des données
- La réduction des données (diviser par l'écart type) permet d'unifier les unités des différentes variables.
- Standardiser les variables (centrage et réduction) permet d'affecter la même importance à toutes les variables.

$$x_{ik} = \frac{x_{ik} - \overline{x_k}}{\sigma_k}$$

Formulation de problème

Soit X une matrice centrée réduite de dimension $n \times p$:

	X_1	X_2	X_3		X_p
$x^{(1)}$					
$x^{(2)}$					
$x^{(i)}$					
$x^{(n)}$					

La matrice de variance covariance est donnée par:

$$S = \frac{1}{n-1}\sum_{i=1}^{n} x^{(i)} x^{(i)^t} = \frac{1}{n-1} X^t X, \text{avec } \mathrm{x}^{(\mathrm{i})} \in \mathbb{R}^{\mathrm{p}\times 1} \text{ and } \mathrm{x}^{(\mathrm{i})}\mathrm{x}^{(\mathrm{i})^{\mathrm{t}}} \in \mathbb{R}^{\mathrm{p}\times \mathrm{p}}$$

Formulation de problème

$$S = \begin{pmatrix} Var(X_1) & \cdots & Cov(X_1, X_p) \\ \vdots & \ddots & \vdots \\ Cov(X_p, X_1) & \cdots & Var(X_p) \end{pmatrix}$$

- S est une matrice symétrique semi définie positive:

$$S^t = \frac{1}{n-1} X^t X = \mathrm{S}$$

Formulation de problème

Soit X une matrice centrée réduite :

	X_1	X_2	X_3		X_p
$X^{(1)}$					
$X^{(2)}$					
$X^{(i)}$					
$X^{(n)}$					

Objectif:

Choisir des nouvelles dimensions $U_1, U_2, \dots, U_q$ tels que la variance de la projection des données est maximale

Formulation de problème

- La première dimension U_1 ou la vriance de projection de données est maximale est le vecteur propre de S avec la grande valeur propre
- La 2ème direction qui maximise la variance de la projection est celui qui correspond à la 2ème plus grande valeur propre, elle est orthogonale à la 1ère, etc
- Les nouvelles dimensions qu'on cherche sont en fait, les vecteurs propres de S
- $S = \frac{1}{n-1} X^t X$ est symétrique semi définie positive, alors elle est diagonalisable, ses valeurs propres sont positives ou nulles et ses vecteurs propres sont orthogonaux

$$S = PDP^{-1} \text{ avec } P^tP = I$$

$$\mathrm{P} = [V_1 \quad V_2 \ldots \quad V_p]$$

Les $V_j = \begin{pmatrix} v_{1j} \\ \vdots \\ v_{pj} \end{pmatrix}$ sont les vecteurs propres de S, les nouvelles dimensions recherchées. Elles sont appelées les axes principaux. D est une matrice diagonale composée des valeurs propres:

$$D = \begin{pmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_p \end{pmatrix}$$

Trouver les facteurs principaux (représentation des individus)

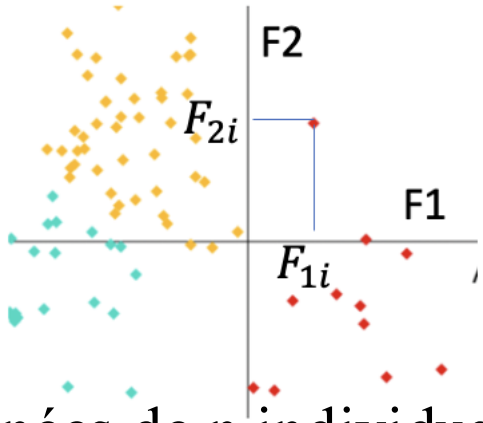
- La projection des données (X) (des individus) dans le nouvel espace déterminé par les vecteurs $[V_1, \quad V_2 \dots \quad V_p]$, est donnée par:

$$XP = X[V_1 \quad V_2 \dots \quad V_p] = [F_1, F_2, \dots, F_p] \in \mathbb{R}^{n \times p}$$

- Les F_j sont appelés facteurs principaux, ou composantes principales, ils sont des combinaisons linéaires des variables initiales:

$$F_k = XV_k = \nu_{1k}X_1 + \nu_{2k}X_2 + \cdots + \nu_{pk}X_p, \forall k \in \{1, \dots, p\}$$

Avec $V_k = \begin{pmatrix} \nu_{1k} \\ \vdots \\ \nu_{pk} \end{pmatrix}$



F_1	F_2	….	F_P
F_{11}	F_{12}		
⋮	⋮		
F_{n1}	F_{n2}		

- Le facteur F_k fourni les coordonnées de n individus sur le $kème$ axe principal

Variances expliquées par les nouveaux facteurs

- La projection des données (X) dans le nouvel espace est donnée par:
- $XP = [F_1, F_2, \dots, F_p] = \begin{pmatrix} F_{11}, & \cdots & F_{1p} \\ \vdots & \ddots & \vdots \\ F_{n1} & \cdots & F_{np} \end{pmatrix}$
- F_{ij} est la cordonnées de l'individu i sur l'axe j
- Les variances des différents facteurs (composantes principales) sont données par les éléments diagonaux de la matrice de variance covariance de XP.
- La matrice de variance covariance de XP est:

$$S' = \frac{1}{n-1}(XP)^t(XP) = \frac{1}{n-1}P^tX^tXP = P^tSP = \begin{pmatrix} Var(F_1), & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & Var(F_p) \end{pmatrix}$$

- Comme $S = PDP^{-1}$, alors $P^tSP = P^tPDP^{-1}P = D = \begin{pmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_p \end{pmatrix}$
- Le pourcentage de variance expliquée par le facteur F_k est donnée par: $\frac{\lambda_k}{\sum_{j=p} \lambda_j}$

Variances expliquées par les nouveaux facteurs

La variance globale (multidimensionnelle) expliquée par les différents facteurs est donnée par:

$$\boldsymbol{Tr(S')} = tr(P^t SP) = tr(D) = \sum_{\boldsymbol{k=1}}^{\boldsymbol{P}} \boldsymbol{\lambda_k}$$

D'autre part, $tr(P^t SP) = \mathrm{tr}(\mathrm{PP}^t S) = \boldsymbol{tr(S)} = \sum_{j=1}^{p} Var(X_j)$

Si les variables sont centrées et réduites alors:

$$tr(S) = \sum_{j=1}^{p} Var(X_j) = p$$

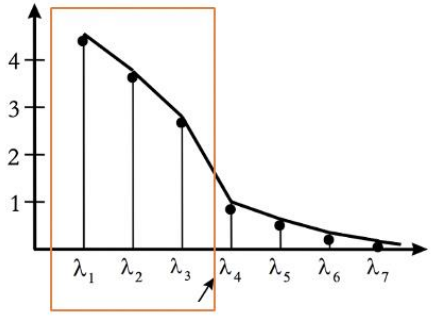
Remarque:

La variance globale (l'inertie de nuage de points) ne change pas après la projection, c'est la répartition de cette dispersion, selon les nouvelles variables qui change. On cherche les nouvelles variables avec la plus grande variance (i.e.principales)

Nombre de facteurs (composantes) à retenir

L'objectif est de garder le maximum d'information possible
Plusieurs critères peuvent être considérés pour choisir le nombre de facteurs à retenir, on peut citer:

- Lorsque les données sont standardisées, on peut retenir les axes avec les valeurs propres supérieure ou égale à 1
- Retenir les premiers facteurs avec une variance cumulée entre 80% et 90%
- Le critère de coude permet de conserver les axes associés aux valeurs propres situées avant le changement brusque de la pente. Les points qui suivent le changement, appelé rupture du coude, semblent former une ligne droite horizontale.



Interprétation des nouveau facteurs

- Pour donner un sens au nouveau facteurs(les interpréter), on calcule la matrice de corrélation variables-facteurs.
- Il s'agit des coefficients de corrélation linéaire entre les variables initiales et les facteurs

	X_1	…	X_p
F_1	ρ_{11}		ρ_{1p}
⋮			
F_p	ρ_{p1}		ρ_{pp}

Avec

$$\rho_{ij} = cor(F_i, X_j)$$

Résumé

- Standardiser les données X
- Calculer la matrice de variance covariance $S = \frac{1}{n-1} X^t X$
- Trouver les valeurs propres et les vecteurs propres de S
- Ordonner les valeurs propres par ordre décroissant
- Construire la matrice de projection P (des vecteurs propres ou des nouvelles dimensions)
- Projeter les individus dans le nouvel espace (XP)
- Sélectionner un nombre de facteurs
- Etudier la corrélation entre les variables initiales et les nouveaux facteurs
- Interpréter les facteurs

N.B: *L'ACP fonctionne bien lorsqu'il existe des corrélations entre les variables initiales. On peut vérifier ça via un indice de* KMO *proche de 1* (≥ 0.6) *et un test de Test de sphéricité de Bartlett Significatif.*

Exemple 4: Analyse en composantes principales sur la BDD iris

L'objectif:

1) Réduire les dimensions de la BDD iris (la partie X) en deux dimensions
2) Représenter les données initiales sur les nouvelles dimensions
3) Vérifier si la nouvelle représentation des données permet de les classifier en classes?

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	class
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.2	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0

- **Importer les librairies nécessaires**

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn import datasets
from sklearn.decomposition import PCA
```

- **Chargement de l'ensemble de données Iris**

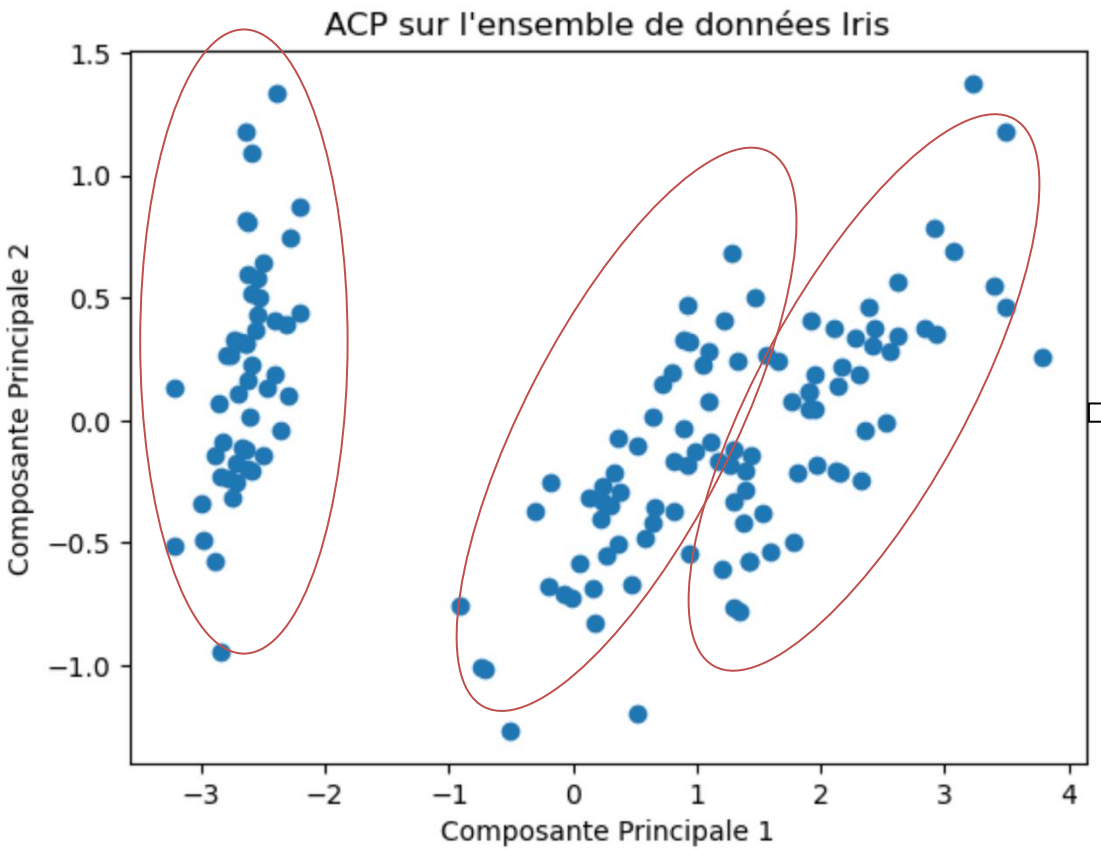
```
iris = datasets.load_iris()
X = iris.data  # Les caractéristiques
y = iris.target  # Les étiquettes (classes)
```

- **Instanciation de l'objet PCA et l'adapter aux données**

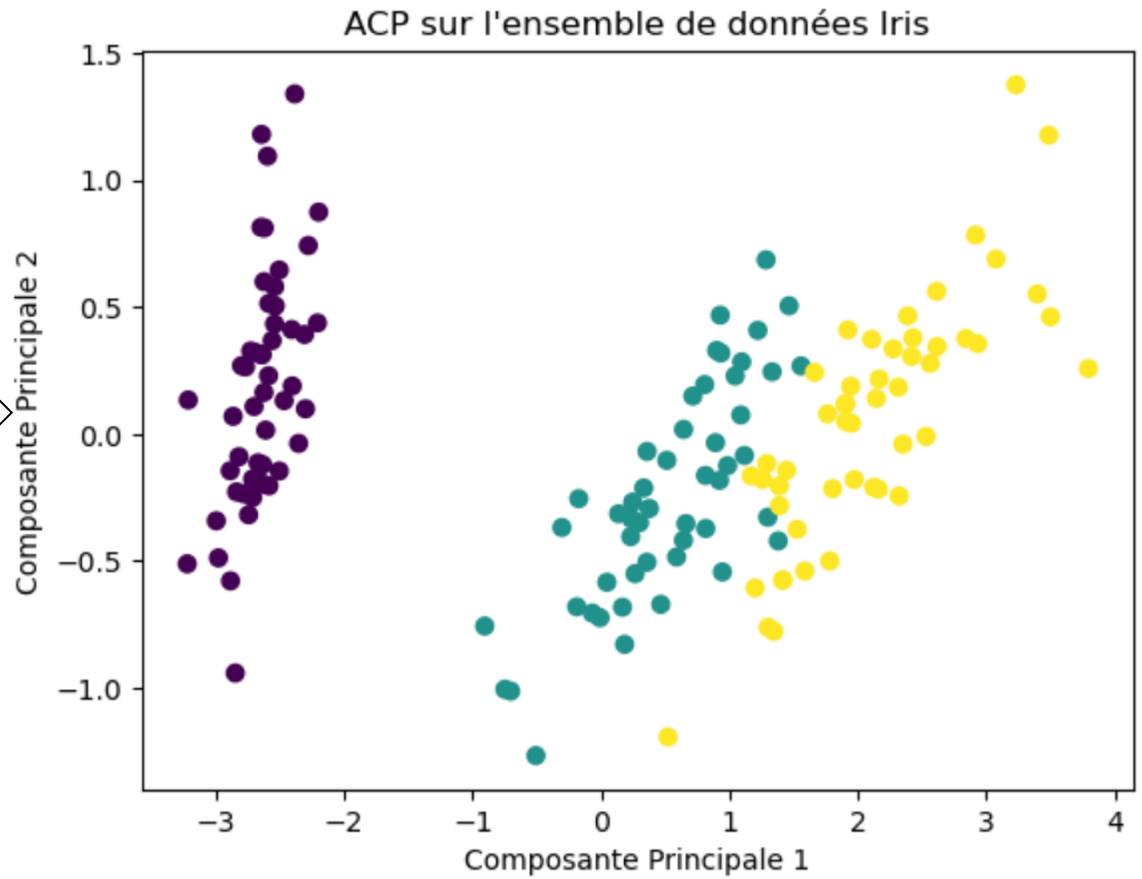
```
pca = PCA(n_components=2)  # Réduction à 2 dimensions
X_pca = pca.fit_transform(X)
```

Affichage des résultats

```
plt.scatter(X_pca[:, 0], X_pca[:, 1])
plt.title('ACP sur l\'ensemble de données Iris')
plt.xlabel('Composante Principale 1')
plt.ylabel('Composante Principale 2')
plt.show()
```



Colorer selon Y



Apprentissage supervisé avec ACP : pipeline complet

1.Construire le pipeline:

- Traitement particulier des variables (cleaner)
- Prétraitement des variables cat/num :
  - Imputation
  - Standardisation
  - One-hot encoding
- Rééquilibrage des classes (SMOTE / ADASYN)
- Sélection de variables (optionnel)
- Réduction de dimension (ACP)
- Modèle (KNN, LR, etc.)

2. Entrainer le pipeline avec les données d'entrainement

3- Evaluation du pipeline avec les données de test

4- Entrainer le pipeline final avec la base de données entière

5- Enregistrer le modèle

6- Déployer le modèle

Ecole Centrale de Casablanca (ECC)

Techniques de Clustering

Prof. Y. Lamrani Alaoui
lamrani@emi.ac.ma
EMI-Rabat

Centrale
CASABLANCA

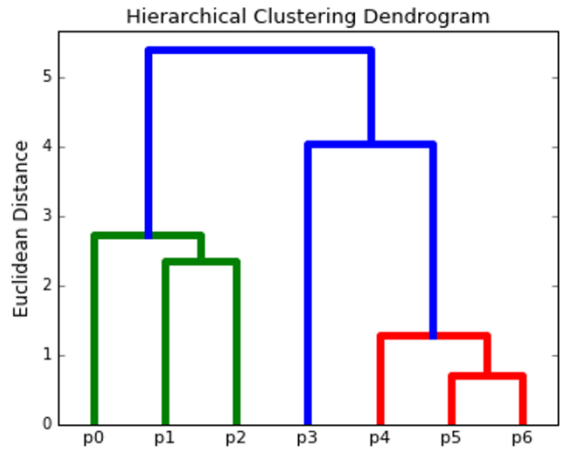
Introduction

- En clustering, on cherche à identifier des groupes d'observations ayant des caractéristiques similaires (ex. comportement d'achats de clients,...)
- Des exemples d'application comprennent:
  - La segmentation de la clientèle d'une entreprise en fonction d'un certain critère (démographique, habitude d'achat etc.
  - Clustering de documents en fonction de leurs contenus.
- Les données pour le clustering ont la même structure que celles de l'ACP

Introduction

On distingue quatre grandes familles de méthodes de clustering :

1. **Clustering par partition** : les données sont réparties directement en K groupes ; K doit être fixé à l'avance (k-means, k-medoids).
2. **Clustering hiérarchique** : on construit une hiérarchie de groupes représentée par un arbre, le **dendrogramme** (approche ascendante ou descendante) ; K est choisi a posteriori en coupant l'arbre (CAH).
3. **Clustering fondé sur la densité** : un cluster est une zone dense, séparée des autres par des régions peu denses ; K n'est pas fixé à l'avance et les points isolés sont traités comme du bruit (DBSCAN, OPTICS).
4. **Clustering probabiliste** (model-based) : les données sont supposées issues d'un mélange de lois ; chaque point reçoit une probabilité d'appartenance à chaque groupe (mélange gaussien GMM, estimé par l'algorithme EM).



Algorithme K-means

Introduction

- L'algorithme $K-means$ (k-moyennes, nuées dynamiques ou des centres mobiles) est un algorithme d'apprentissage non supervisé dédié au clustering non hiérarchique.
- Deux individus similaires auront une distance réduite (euclidienne,….) alors que deux individus différents auront une distance de séparation plus grande.

Algorithme

Étape 0 Choisir aléatoirement K centroïdes(lignes de la matrice des données), $\mu_1, \ldots$ à μ_K.

Répéter jusqu'à convergence{

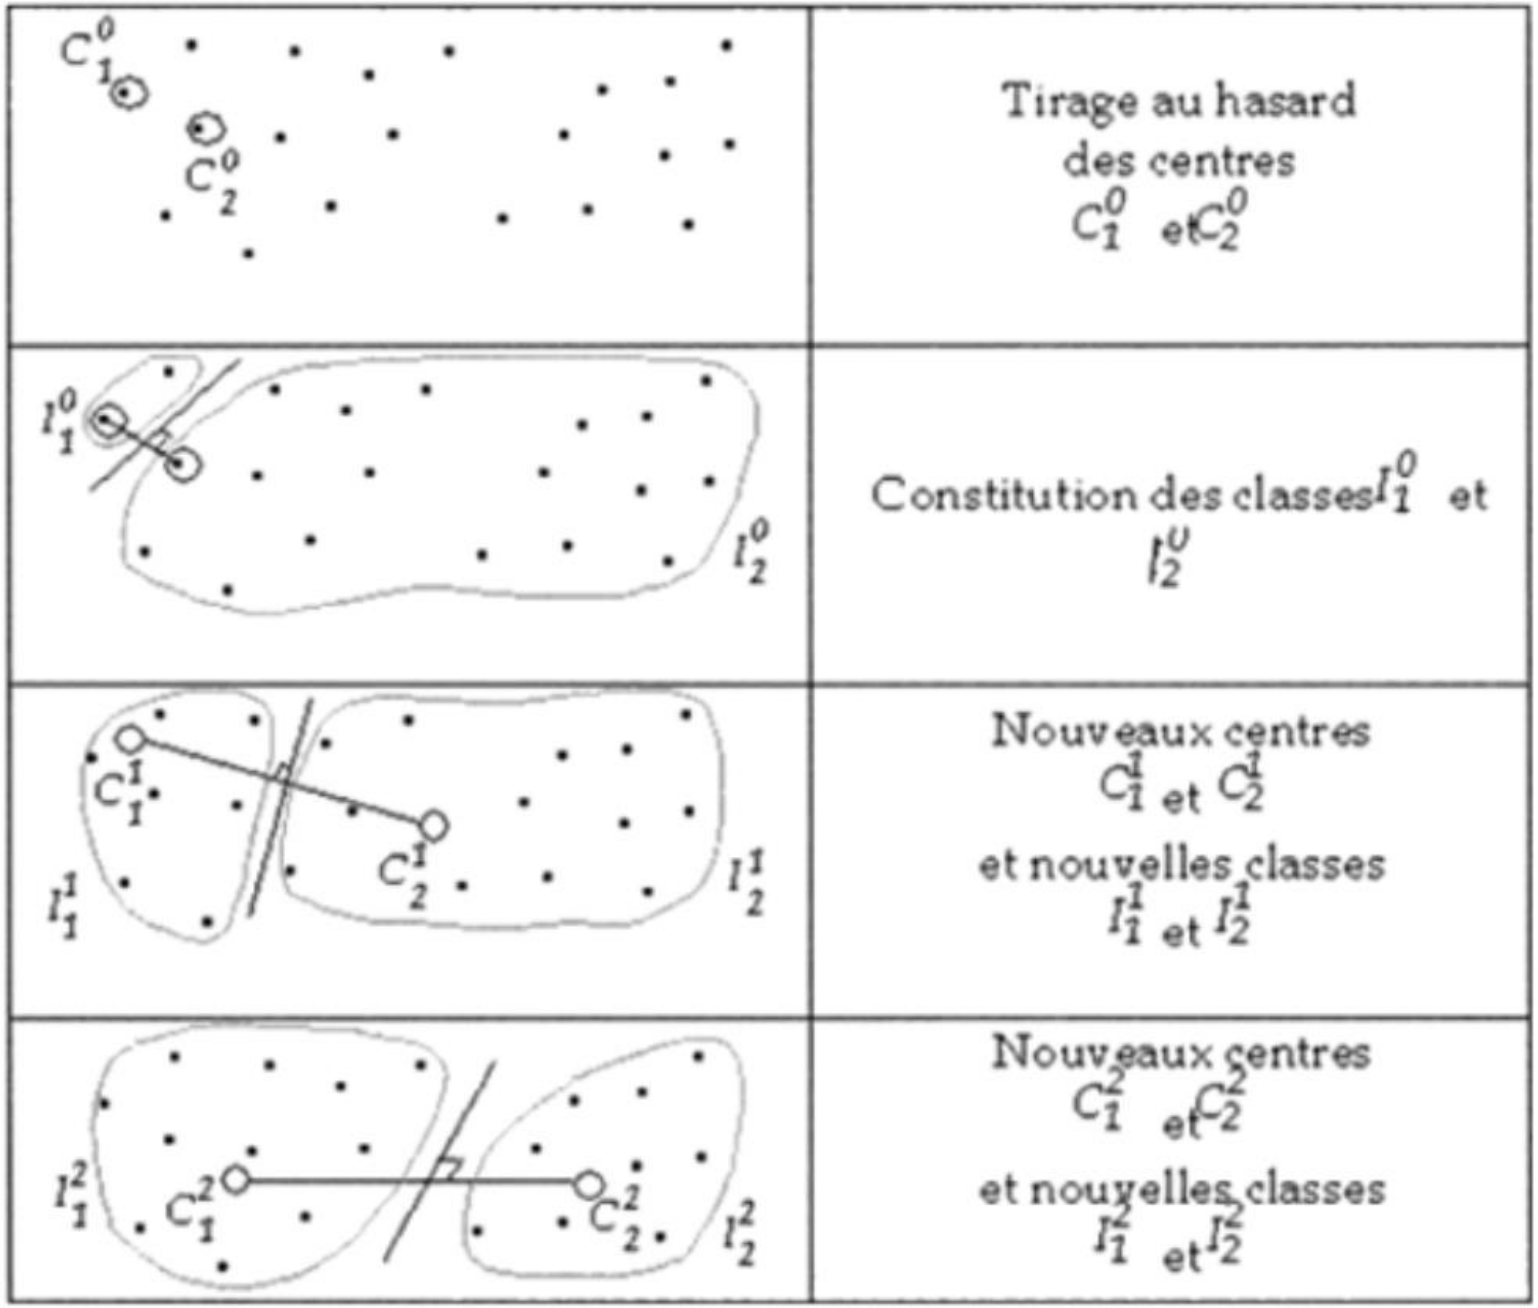
- Étape 1: Affecter chaque individu (ligne) au groupe dont le centroïde est le plus proche
- Étape 2: Recalculer le centroïde de chaque cluster

}

N.B:

- Le centroïde d'un cluster ou son centre est la moyenne des individus qui lui appartient.
- C'est un vecteur avec le même nombre d'éléments que chaque autre individu de la BDD.
- La distance entre un individu i et le centre d'un cluster k est mesurée par : $||x_i - \mu_k||^2$

Animation: https://shabal.in/visuals/kmeans/1.html



Source: Data mining et statistique décisionnelle: l'intelligence des données, Stéphane Tufféry

Fonction de coût à minimiser

L'algorithme cherche à minimiser la fonction :

$$J(c^{(1)}, \dots, c^{(i)} \dots, c^{(n)}, \mu_1, \dots, \mu_K) = \frac{1}{n}\sum_{i=1}^{n} \left\| x_i - \mu_{c^{(i)}} \right\|^2$$

Avec

- μ_k : le centroïde du groupe k
- $c^{(i)}$: l'indice du groupe auquel l'individu i a été affecté
- $\mu_{c^{(i)}}$: le centre de groupe auquel l'individu i a été affecté
- Cette fonction est appelée : « *Distortion function* »

Intuition de l'algorithme:

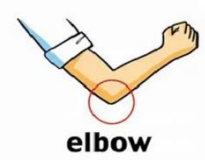
1) Fixer les moyennes $\mu_1, \dots$ à μ_K et mettre ajouter les $c^{(i)}$ pour minimiser J, c'est-à-dire choisir les $c^{(i)}$ qui minimisent $\left\| x_i - \mu_{c^{(i)}} \right\|^2$. On cherche à minimiser la distance entre chaque point de la data et le groupe auquel il est affecté!

2) Fixer les $c^{(i)}$ et recalculer les μ_k pour minimiser $\left\| x_i - \mu_{c^{(i)}} \right\|^2$

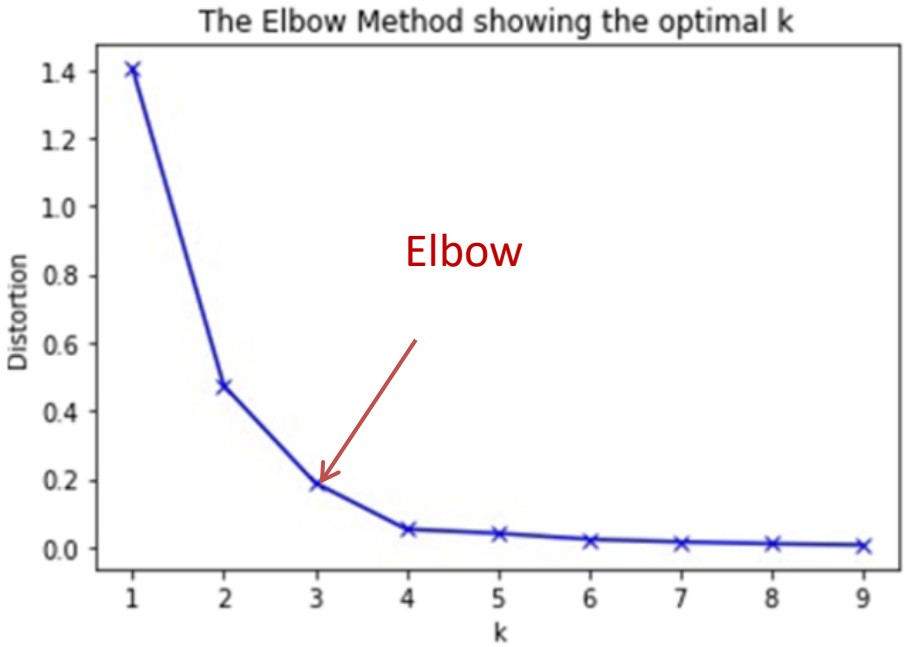
Choisir le nombre de clusters

- Le $K-means$ n'est pas capable de déterminer le nombre optimal de classes ; c’est à l’utilisateur de le spécifier au départ.
- Un nombre élevé de classes peut conduire à un partitionnement trop fragmenté des données, tandis qu'un nombre de clusters trop faible conduira à des clusters trop généralistes contenant une grande quantité de données.
- Il est important de choisir le nombre de clusters qui peut mettre en lumière des structures intéressantes dans les données.

Choisir le nombre de clusters



- Pour choisir le nombre optimal de clusters, on peut lancer le $K-means$ plusieurs fois, avec différentes valeurs de K et puis on calcule la valeur de la fonction coût.
- Généralement, en mettant dans un graphique les différents nombres de clusters K en fonction de la fonction coût (règle de coud ou *Elbow method* en anglais).
- Le nombre optimal de clusters est le point représentant le coude.



Dans l'exemple ci-dessus le coude peut être représenté par K valant 2 ou 3. C'est le nombre optimal de clusters.

Les avantages et les limites

- Le $K-means$ est capable de traiter des très grandes bases de données
- L'initialisation des premiers K centroïdes est aléatoire. Par conséquent le résultat de l'algorithme peut être différent d'une lancé à l'autre.
- Il est donc conseillé de relancer plusieurs fois l'algorithme pour sélectionner la répartition avec la fonction coût la plus faible.

TP: Clustering avec K-means : BDD iris

1. Effectuer un clustering des données iris (la partie X), prenez $K = 3$
2. Trouver la valeur optimale de K à l'aide de la méthode de coud
3. Calculer le coefficient de silhouette pour la répartition optimale trouvé
4. Visualiser la qualité des clusters à l'aide du diagramme silhouette.
5. Visualiser les groupes créés

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	class
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.2	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0

- **Importer les librairies nécessaires**

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA
from sklearn import datasets
from sklearn.metrics import silhouette_score,silhouette_samples
```

- **Chargement de l'ensemble de données Iris**

```
iris = datasets.load_iris()
X = iris.data  # Les caractéristiques
y = iris.target  # Les étiquettes (classes)
```

- **Instanciation de l'objet PCA et l'adapter aux données**

```
pca = PCA(n_components=2)  # Réduction à 2 dimensions
X_pca = pca.fit_transform(X)
```

- **Instanciation de l'objet *KMeans* et l'adapter aux données**

```
kmeans = KMeans(n_clusters=3, random_state=123,n_init=10)
kmeans.fit(X_pca)
```

- **Obtenir les centres des clusters et les étiquettes de chaque point de données**

```
centers = kmeans.cluster_centers_
labels = kmeans.labels_
```

- **Représenter les étiquettes trouées par clustering sur les composantes principales**

```
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=labels)
plt.title('Clustering K-Means')
plt.xlabel('CP1')
plt.ylabel('CP2')
```



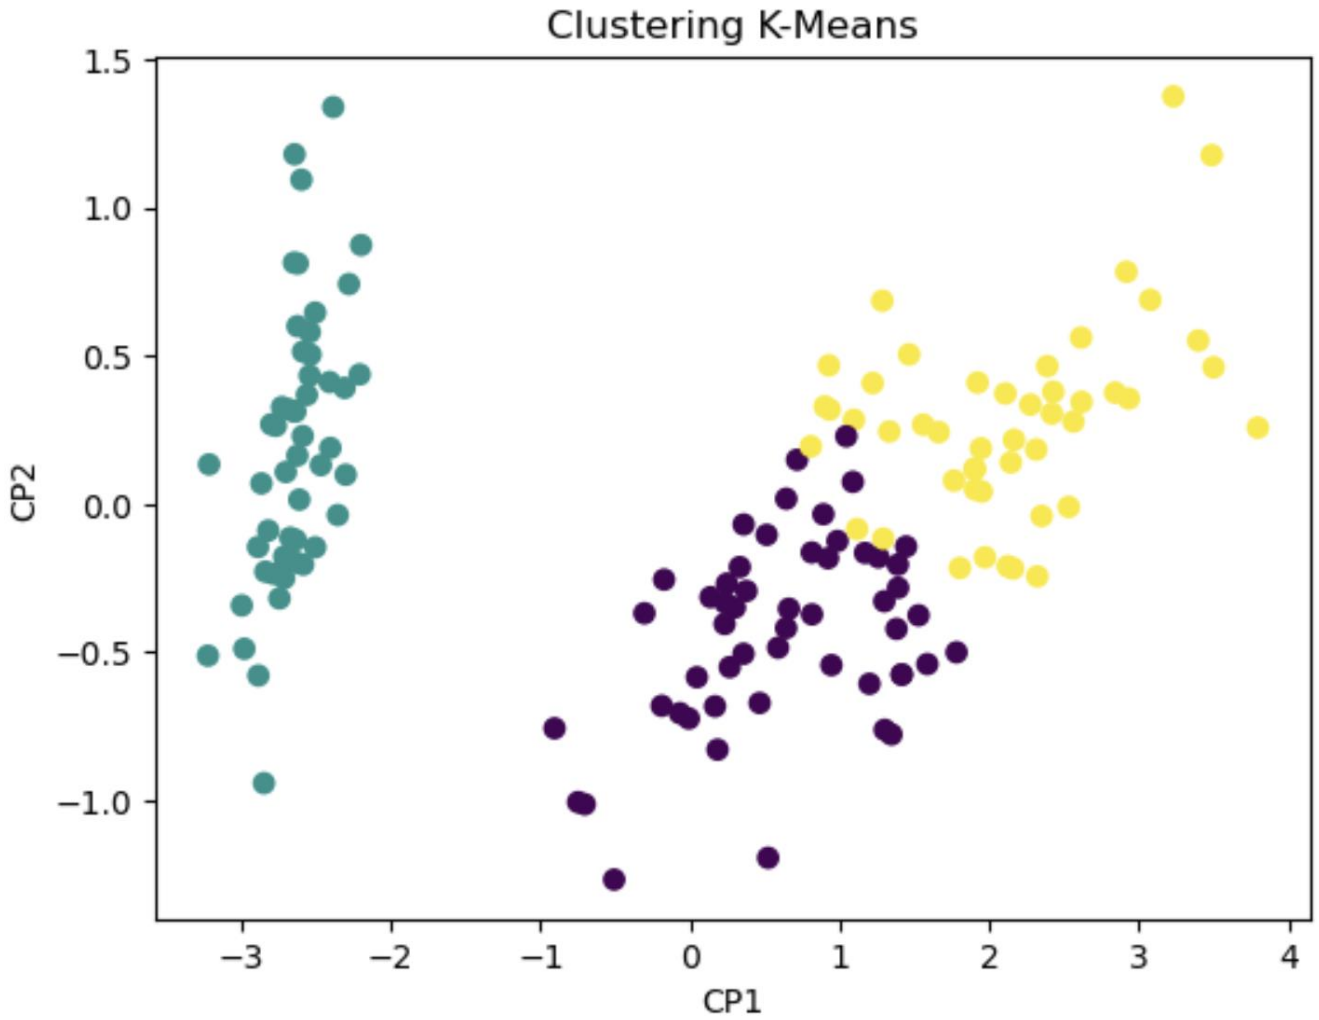


Fig. Résultat de K-means

- Evaluer le modèle en calculant l'indice de silhouette globale

```
score_sil=silhouette_score(X_pca,kmeans.labels_)
print(score_sil)
```

- Evaluer le modèle en calculant l'indice de silhouette pour chaque cluster

```
sample_Sil_val=silhouette_samples(X_pca,kmeans.labels_)
for i in set(model.labels_):
    sil_moy_clust=sample_Sil_val[kmeans.labels_==i].mean()
    print(sil_moy_clust)
```

Hierarchical Agglomerative Clustering

(Classification Ascendante Hiérarchique (CAH))

Introduction

- La classification ascendante hiérarchique (CAH) permet de :
  - Montrer les liens hiérarchiques entre des individus ou des groupes d'individus
  - Identifier un nombre de classes(clusters) homogènes dans une population.

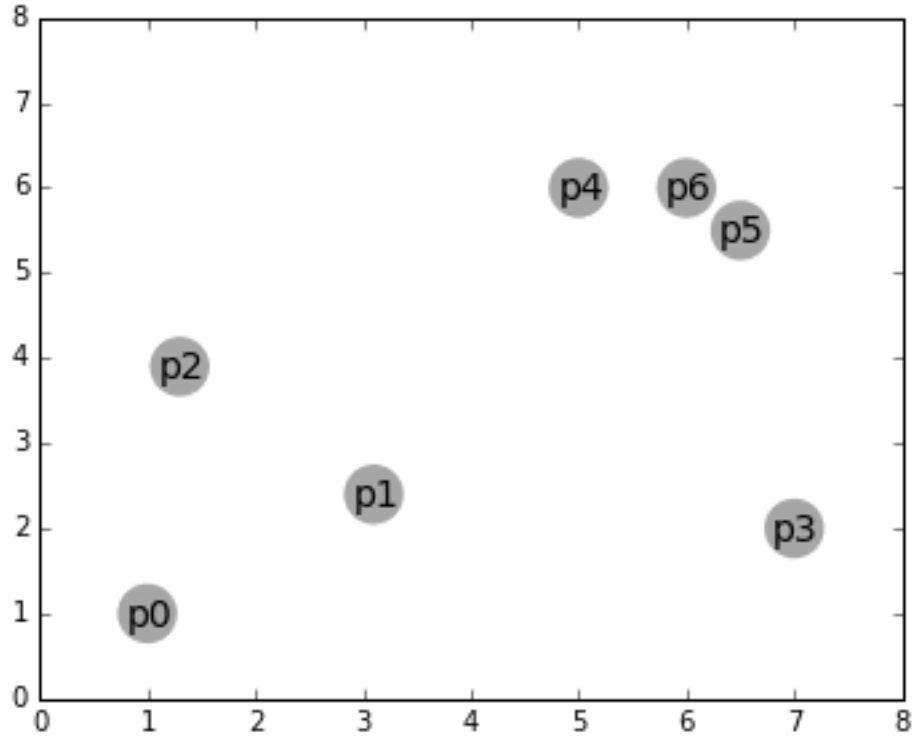
- La CAH cherche à ce que les individus au sein d'une même classe soient les plus semblables possible, tandis que les individus appartenant à des classes différentes sont les plus dissemblables possible.

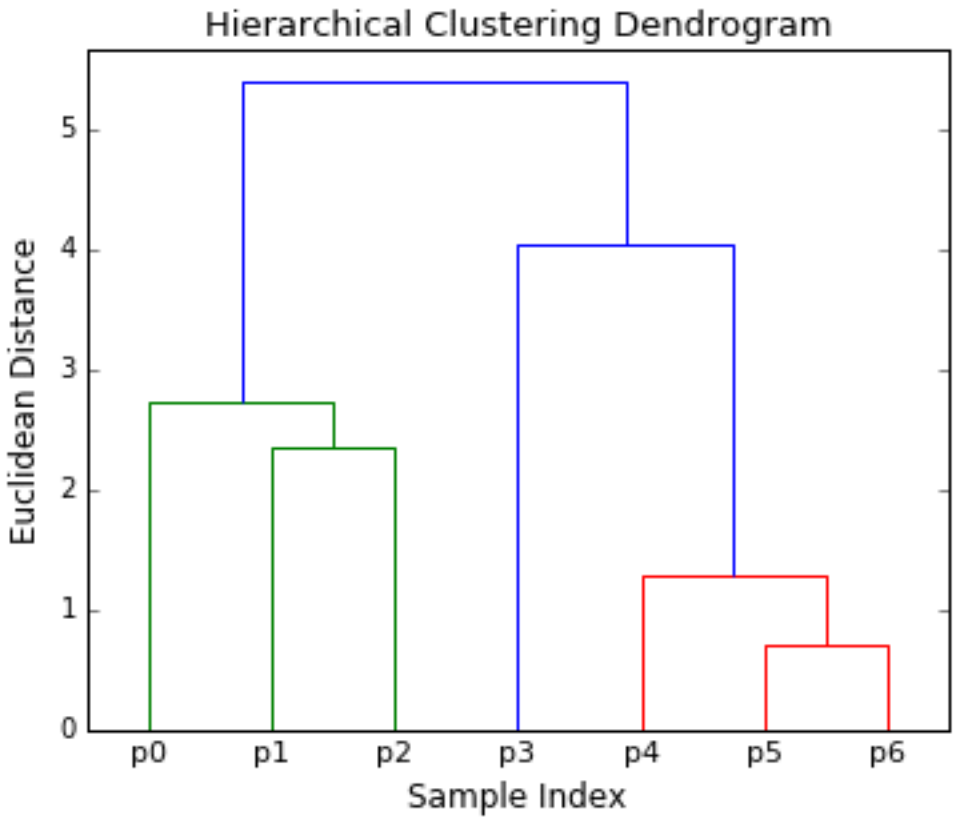
Algorithme

- Calculer le tableau des distances entre tous les individus, chaque individu forme un groupe (classe).
- Tant que tous les individus ne forment pas un seul groupe, répéter{
  - Détecter les 2 groupes les plus proches (similaire)
  - Les agréger dans un seul groupe }

- Identifier le nombre adéquat de groupes
- Procéder au partitionnement

Algorithme: Exemple illustratif





Algorithme: Exemple illustratif

Soit un ensemble avec 7 éléments : $p_0, p_1, p_2, p_3, p_4, p_5, p_6$
La CAH peut poursuivre les partitions suivantes:

- Etape 0: $p_0, p_1, p_2, p_3, p_4, p_5, p_6$
- Etape 1: $p_0, p_1, p_2, p_3, p_4, \{p_5, p_6\}$
- Etape 2: $p_0, p_1, p_2, p_3, \{p_4, p_5, p_6\}$
- Etape 3: $p_0, \{p_1, p_2\}, p_3, \{p_4, p_5, p_6\}$
- Etape 4: $\{p_0, p_1, p_2\}, p_3, \{p_4, p_5, p_6\}$
- Etape 5: $\{p_0, p_1, p_2\}, \{p_3, p_4, p_5, p_6\}$
- Etape 6: $\{p_0, p_1, p_2, p_3, p_4, p_5, p_6\}$

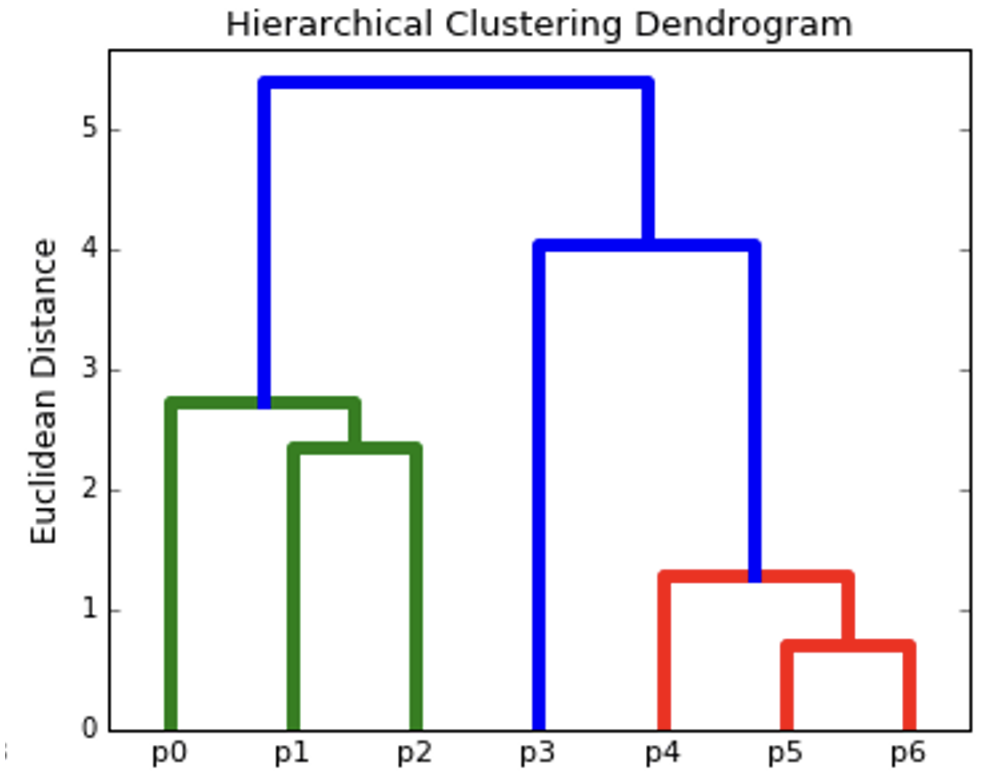


Fig. Dendrogram

Critères de ressemblance (d'agrégation)

On fait la différence entre deux types de critères de ressemblance (d'agrégation) :

1. Les critères de ressemblance ***(metric)*** entre des individus, celui-ci peut être abordé par le biais de la notion de distance:
   - Distance euclidienne;
   - Distance de Manhattan;
   - Distance de maximum;
   - Distance de Minkowski
2. Les critères de ressemblance entre des groupes d'individus **(linkage criterion)**:
   - Méthode du saut minimum (single linkage ou nearest neighbor)
   - Méthode du saut maximum (complet linkage ou furthest neighbor)
   - Méthode de la distance moyenne (average linkage)
   - Méthode de Ward,...

N.B: Le choix de critère de ressemblance peut modifier le résultat de la CAH

Ressemblance entre groupes d'individus

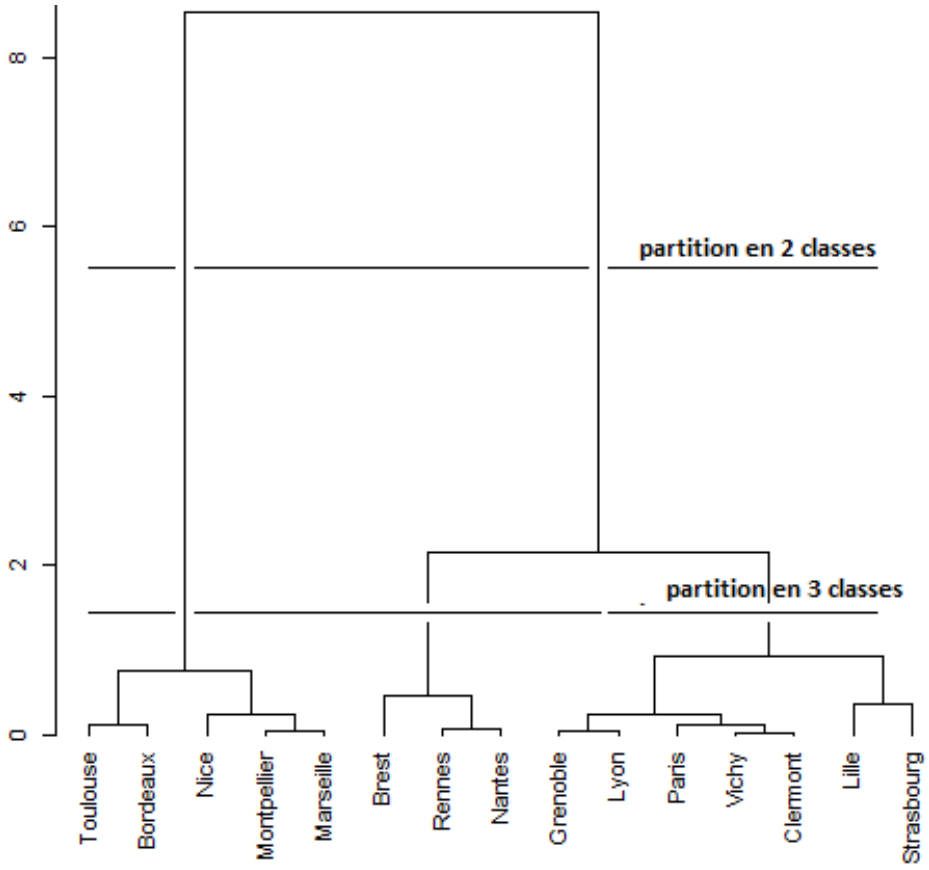
Méthode de Ward : la distance entre deux classes A et B est l'augmentation de l'inertie intra-classe due à leur fusion :

$$\frac{n_a \; n_b}{n_a \; + \; n_b} \; d^2(\mu_a, \mu_b)$$

- $n_a \; et \; n_b$ sont les effectifs de A et de B respectivement et $d^2(\mu_a, \mu_b)$ est le carré de la distance euclidienne entre les centres de gravité de A et de B.
- La méthode de Ward est la méthode par défaut dans de nombreux logiciels statistiques.
- La méthode de Ward fusionne, à chaque étape, les deux classes dont la fusion fait perdre le moins d'inertie interclasse : l'inertie interclasse reste ainsi maximale.

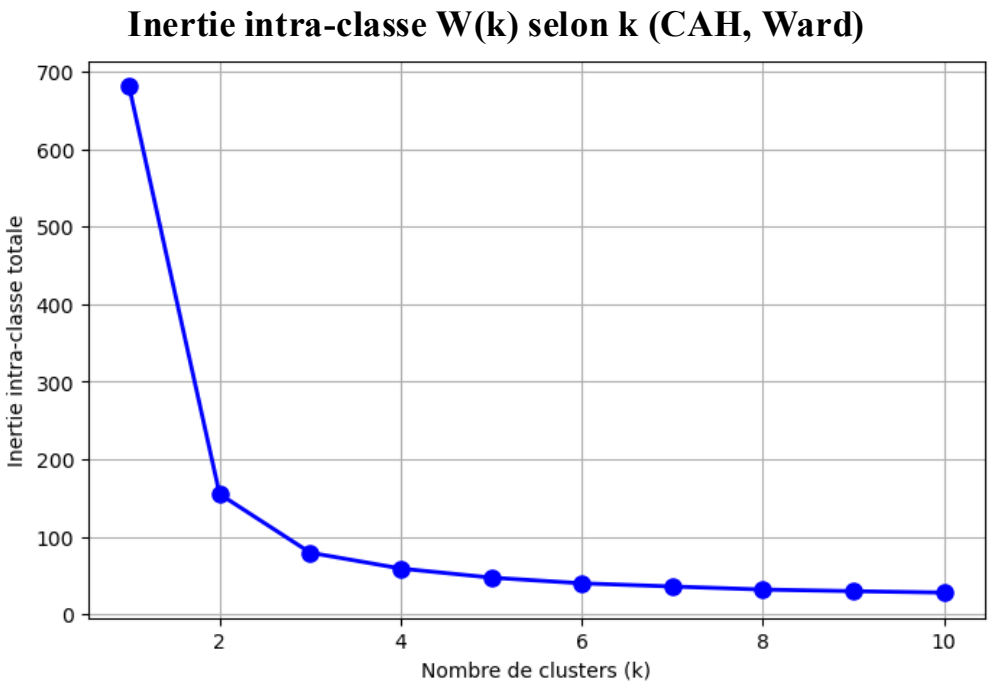
Nombre de classes à retenir

- Dans une CAH, l'arbre hiérarchique (**Dendrogramme**) décrit un ensemble de partitions possibles
- Il suffit de découper le dendrogramme obtenu à une certaine hauteur pour obtenir une partition de la population.
- Une partition naturelle se fait en coupant l'arbre au niveau du plus grand saut de nœuds



Nombre de classes à retenir

- **Méthode du coude** : on trace l'inertie intra-classe W(k) en fonction du nombre de classes k (critère de Ward).
- W(k) diminue toujours quand k augmente : on retient le k au-delà duquel une classe de plus ne réduit presque plus l'inertie, c'est le **« coude »**.
- **Ici** : W passe de ≈ 680 à ≈ 155 (k = 2), puis ≈ 80 (k = 3) ; au-delà, les gains sont inférieurs à 20, donc on retient **k = 3**.
- À confirmer avec le dendrogramme (couper au plus grand saut de hauteur) et par l'interprétation des classes.

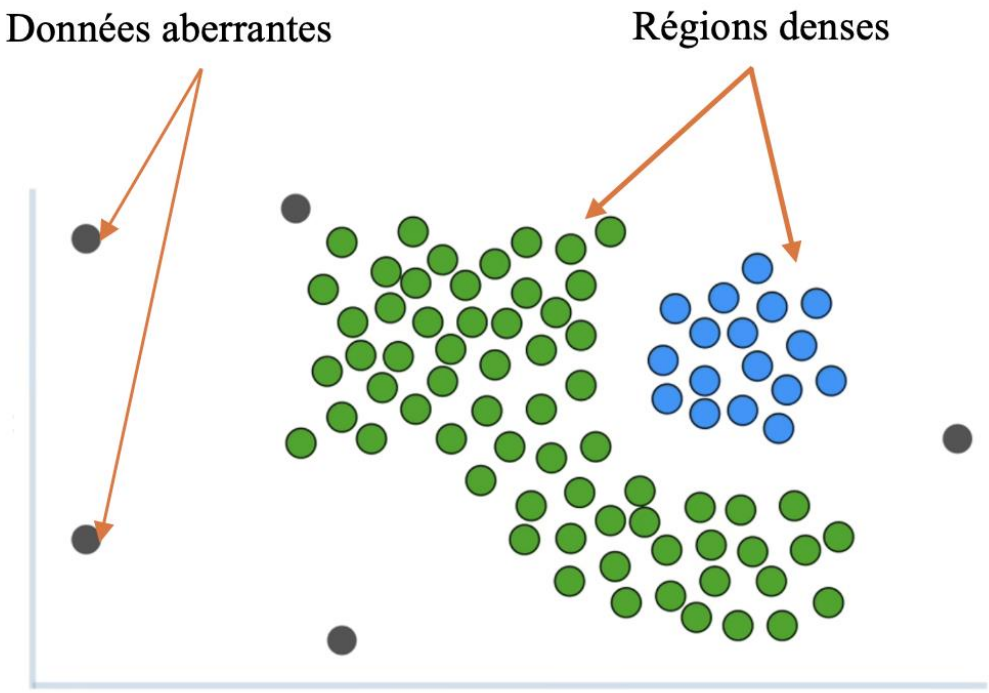


DBSCAN

(Density Based Spatial Clustering of Applications with Noise)

DBSCAN

- L’idée de DBSCAN est de regrouper les points proches; les régions denses forment des clusters.
- Un points qui n’appartient à aucune région dense est considéré comme aberrants (outliers)
- DBSCAN est aussi une méthode de détection d’anomalies



DBSCAN

Avantages:

- Aucune nécessité de spécifier le nombre de clusters
- Détecte des clusters de formes arbitraires (contrairement à K-Means).
- Identifie naturellement les outliers (points isolés).
- Bien adapté aux données spatiales et aux groupes de densité variable.

Évaluer la performance d’un modèle de Clustering

Évaluer la performance d'un modèle de Clustering

Une bonne méthode de clustering (regroupement) vise à produire des groupes d'individus présentant une forte homogénéité interne et une distinction importante entre groupes. Cela se traduit par :

- Une **forte similarité intra-cluster**, favorisant l'homogénéité des éléments au sein d'un même groupe.
- Une **faible similarité inter-cluster**, garantissant une bonne séparation entre les différents groupes

Évaluer la performance d'un modèle de clustering

1- Inertie intra-class (Within-Cluster Sum of Squares):

Une inertie faible indique une bonne répartition, cependant, une valeur très faible peut indiquer un overfitting quand le nombre de clusters est très élevé

$$J_w = \sum_{k=1}^{K} \sum_{x_i \in G_k} \|x_i - \mu_k\|^2$$

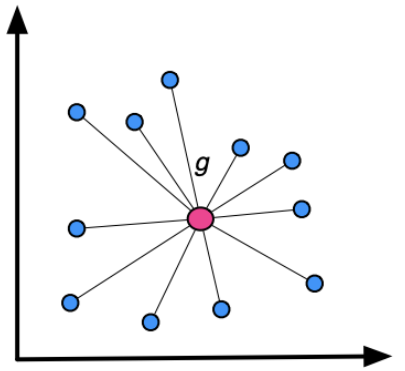


Fig. inertie intra-classe

- K: le nombre de clusters
- G_k: l'ensemble de points dans le cluster k
- μ_k est le centroïde du cluster k
- x_i est un point de données

Évaluer la performance d'un modèle de clustering

2- L'inertie inter-classe mesure l'éloignement des centres des groupes entre eux. Ainsi, plus l'inertie inter-groupe est grande, plus les groupes sont bien distincts.

- Soit $\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$ la moyenne des données indépendamment de leur groupe d'appartenance
- L'inertie inter-classe est donnée par:

$$J_b = \sum_{k=1}^{K} n_k \|\mu_k - \mu\|^2$$

- n_k est le nombre de points dans le cluster k.
- μ est le centroïde global (le barycentre de l'ensemble des données).

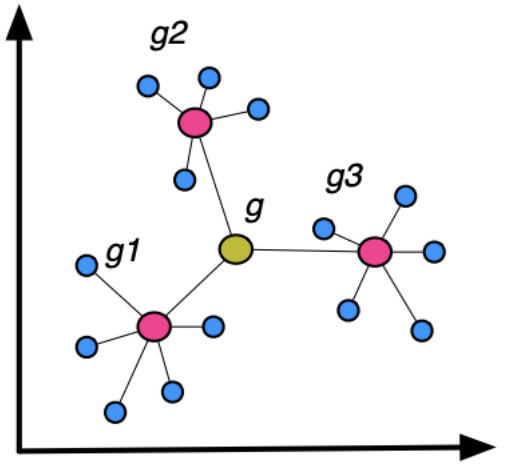


Fig. inertie inter-groupes

Évaluer la performance d'un modèle de clustering

3- Indice de Silhouette mesure la similarité des individus avec leur propre cluster (la cohésion interne) par rapport aux autres clusters (la séparation externe). Sa valeur varie entre -1 et 1, une valeur élevée indique une bonne répartition.

- Le coefficient de silhouette se définit d'abord sur un point i dont le groupe $k = c(i)$
- Il se base sur la distance moyenne entre le point i et tous les autres points du même groupe (la cohésion interne) :

$$a(i) = \frac{1}{n_k - 1} \sum_{j=1, j \neq i}^{n_k} d(x_i, x_j)$$

N.B: On cherche un $a(i)$ faible!

Évaluer la performance d'un modèle de clustering

- Et la distance moyenne du point i et les points de son groupe voisin (la séparation inter-groupe)

$$b(i) = \min_{k' \neq k} \frac{1}{n_{k'}} \sum_{j=1}^{n_{k'}} d(x_i, x'_j)$$

k est le cluster de i , k' est un autre cluster avec un nombre d'éléments égale à $n_{k'}$.

N.B: On cherche un $b(i)$ élevé!

- Le coefficient de silhouette pour le point i est donné par:

$$S(i) = \frac{b(i) - a(i)}{\max\big(a(i), b(i)\big)}$$

Évaluer la performance d'un modèle de clustering

- On peut le moyenner groupe par groupe pour comparer leurs homogénéités: ceux avec les coefficients de silhouette les plus forts sont les plus homogènes. Le score de silhouette d'un groupe k est donné par:

$$S_k = \frac{1}{n_k} \sum_{i=1}^{n_k} S(i)$$

- Sur l'ensemble de classification, il aura pour expression :

$$S = \frac{1}{K} \sum_{k=1}^{K} \frac{1}{n_k} \sum_{i=1}^{n_k} S(i)$$

- L'indice de silhouette peut être utilisé également pour déterminer le nombre optimal de clusters K. En comparant les indices de silhouette pour différentes valeurs de K, on peut déterminer la meilleure partition pour les données.

Évaluer la performance d'un modèle de clustering

- La figure montre une bonne séparation d'un ensemble de données en quatre groupes.
- Sur l'axe des ordonnées sont représentées les données des différents groupes selon le regroupement utilisé.
- L'axe des abscisses représente la valeur de l'indice de silhouette calculé pour chaque point i.
- L'indice de silhouette est positif pour la majorité des points, sauf pour 6 individus (1 appartenant à G1 et 5 à G2). Ce qui démontre l'homogénéité des données au sein des différents groupes.

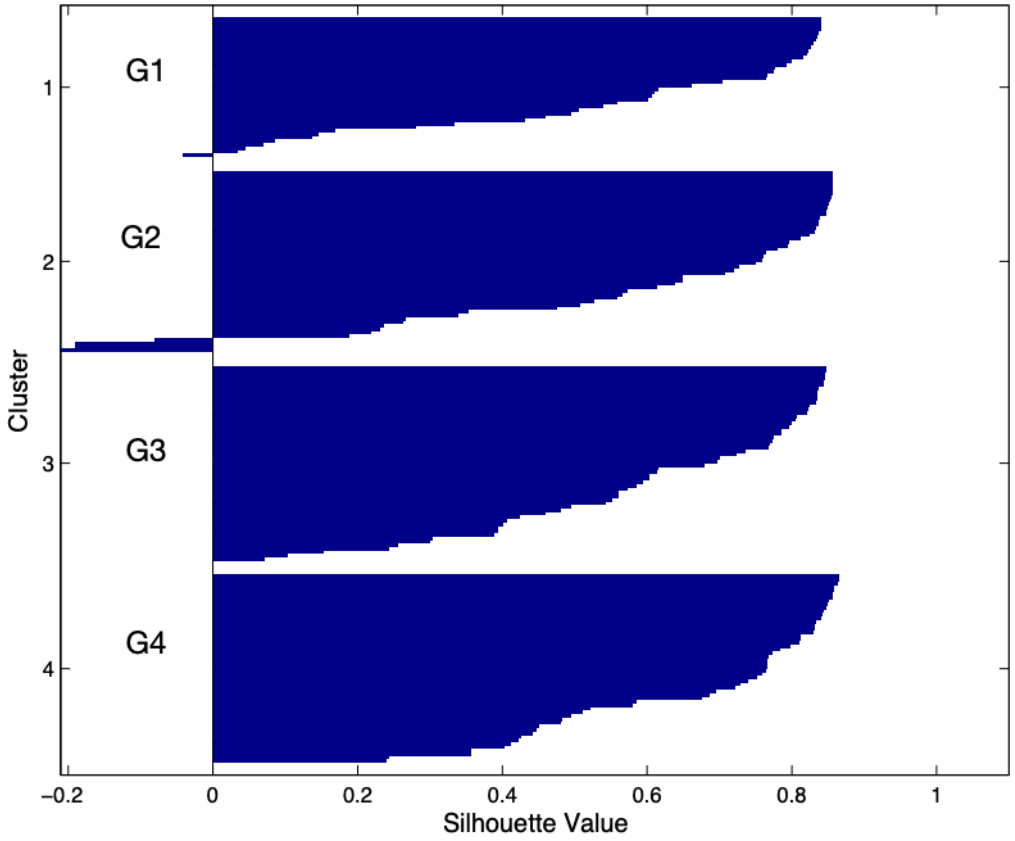


Fig. Indice de silhouette d'un ensemble de données en 4 groupes.

Évaluer la performance d'un modèle de clustering

4- Indice de Davies–Bouldin (DB)

- L'objectif de cet indice est de mesurer simultanément la **compacité intra-cluster** (les points d'un même cluster sont proches), et la **séparation inter-clusters** (les clusters doivent être bien distincts).
- Pour chaque cluster, on compare sa **dispersion interne**, à la **distance qui le sépare des autres clusters**.
- L'indice final est la moyenne du "pire cas" de similarité entre clusters.

Pour un clustering en k clusters:

$$DB = \frac{1}{k}\sum_{i}^{k} \max_{i \neq j}\left(\frac{S_i + S_j}{d(c_i, c_j)}\right)$$

S_i: dispersion du cluster i (distance moyenne des points au centroïde)
c_i: centroïde du cluster i
$d(c_i, c_j)$: distance entre les centroïdes des clusters i et j
→ **Plus l'indice est petit, meilleur est le clustering.** Un $DB = 0$ correspond à un clustering parfait!

Évaluer la performance d'un modèle de clustering

5- Indice de Calinski–Harabasz (CH)

- L'indice de **Calinski–Harabasz** est une **métrique interne de validation du clustering**.
- Il compare la dispersion entre les clusters (séparation), à la dispersion à l'intérieur des clusters (compacité).
- L'indice CH mesure précisément ce **rapport séparation / compacité**. Plus ce rapport est élevé, plus la structure de clustering est pertinente.
- Il est particulièrement utilisé pour comparer plusieurs partitions obtenues pour différentes valeurs de k , et aider au choix du nombre optimal de clusters.

L'indice de **CH est donnée par:**

$$CH(k) = \frac{B_k/(k-1)}{W_k(n-k)}$$

Évaluer la performance d'un modèle de clustering

5- Indice de Calinski–Harabasz (CH)

Avec :

W_k: la variance intra-clutsrs donnée par : $\boldsymbol{W_k = \sum_i^k \sum_{x \in C_i} ||x - c_i||^2}$

B_k: la vriance inter-clusters : $\boldsymbol{B_k = \sum_i^k n_i ||c_i - c||^2}$

n: le nombre total d'observations
k: le nombre de clusters
n_i: le nombre d'observations dans le cluster i
c_i: le centroïde du cluster i
c: centroïde global du jeu de données

Limites

→ Sensible à la forme des clusters
→ Peut favoriser un nombre de clusters élevé
→ Moins adapté aux clusters non sphériques (DBSCAN)

Décrire les clusters obtenus

1. **Profil statistique de chaque cluster**
   - Effectif et poids relatif (%), moyennes ou médianes et dispersions des variables actives, coordonnées des centroïdes.
2. **Variables qui discriminent les clusters**
   - Comparaison des moyennes : ANOVA (ou Kruskal-Wallis si les hypothèses ne tiennent pas), puis tests post-hoc (Tukey, Dunn) ; variables qualitatives : test du χ^2 et V de Cramer
3. **Validation par des variables externes**
   - Variables illustratives non utilisées pendant le clustering(quantitatives ou qualitatives).
4. **Visualiser, nommer, vérifier la robustesse**
   - Projection colorée par cluster, boîtes à moustaches par groupe.
   - Nommer chaque cluster à partir de 2 ou 3 variables saillantes

Ecole Centrale de Casablanca (ECC)

La détection d'anomalies

Prof. Y. Lamrani Alaoui
lamrani@emi.ac.ma
EMI-Rabat

Centrale
CASABLANCA

Introduction

- La détection d'anomalies est le processus d'identification d'éléments, d'événements ou d'observations rares qui se distinguent significativement de la majorité des données.
- La détection d'anomalies est utilisée dans de nombreux secteurs d'activités:
  - Finance: détection de fraude, fausse déclaration d'impôts,…
  - Fabrication: identifier les défauts et les dysfonctionnements des équipements
  - Cybersécurité: détecter les activités inhabituelles des réseaux
  - Soins de santés: identifier les conditions anormales des patients (maladies,…)
  - Consommation d'Energie: surveiller la consommation d'énergie et identifier les anomalies d'utilisation

Introduction

- Les anomalies des données (données aberrantes) peuvent avoir un impact négatif en sciences des données conduisant à des conclusions incorrectes ou trompeuses.
- Les anomalies des données peuvent avoir un impact négatif sur la performance des modèles de ML

Introduction

Les méthodes de détection d'anomalies sont nombreuses:

- Méthodes statistiques:
  - Visualisation
  - Z-score
  - Tests statistiques (test de Grubbs)
- Méthode d'apprentissage automatique (ML):
  - Non supervisé: **DBSCAN**, **Multivariate Gaussian distribution**, **Modèle de Mélange Gaussien,** Isolation forest, One-class SVM, Autoencodeurs, Local Outlier Factor(LOF),…
  - Supervisé: SVM, random forest,…

La Distribution Gaussienne Multivariée

La Distribution Gaussienne Multivariée de paramètres $\boldsymbol{\mu}$ et $\boldsymbol{\Sigma}$ est une généralisation de la distribution gaussienne unidimensionnelle (univariée) à des dimensions supérieures.

- $\boldsymbol{\mu} = (\boldsymbol{\mu_1}, \boldsymbol{\mu_2}, \dots, \boldsymbol{\mu_p})^{\boldsymbol{T}} \in \mathbb{R}^{\boldsymbol{p}}$ est **vecteur moyen** représentant le centre de la distribution.
- $\boldsymbol{\Sigma} \in \mathbb{R}^{\boldsymbol{p}\times\boldsymbol{p}}$ est la matrice **de covariance (symétrique définie positive)** décrivant la forme de la distribution.

Un vecteur aléatoire $X = (X_1, X_2, \dots, X_n)^T$ suit une distribution gaussienne multivariée si sa fonction de densité de probabilité (PDF) est donnée par:

$$\boldsymbol{p(x;\mu;\Sigma)} = \frac{\mathbf{1}}{\boldsymbol{(2\pi)^{\frac{p}{2}}|\Sigma|^{\frac{1}{2}}}} \mathbf{exp}\left(-\frac{\mathbf{1}}{\mathbf{2}}\ \boldsymbol{(x-\mu)^T\Sigma^{-1}(x-\mu)}\right.$$

Où :

- $x = (x_1, x_2, \dots, x_p)$ est une réalisation du veceteur aléatoire X
- $\boldsymbol{|\Sigma|}$ est le déterminant de la matrice de covariance.
- p est le nombre de variables de la base de données

La Distribution Gaussienne Multivariée

Les paramètres de la distribution peuvent être calculés comme suit:

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i$$

avec $x_i \in \mathbb{R}^p$, il représente une ligne de la BDD

$$\Sigma = \frac{1}{\mathrm{n}}\sum_{i=1}^{n}(x_i - \mu)(x_i - \mu)^T$$

La Distribution Gaussienne Multivariée

Algorithme de détection d'anomalies:

1. Collecter et prétraiter les données y compris la standardisation
2. Estimer les paramètres $\boldsymbol{\mu}$ et $\boldsymbol{\Sigma}$ de la Distribution Gaussienne Multivariée à partir des données d'entraînement.
3. Calculer la probabilité $p(x_i)$ de chaque point de données à l'aide de la formule de PDF
4. Définir un seuil ϵ pour la détection d'anomalies. Les points de données avec des probabilités inférieures au seuil ($p(x_i) \leq \epsilon$) sont classés comme des anomalies.
5. Évaluer le système de détection d'anomalies (le modèle) en calculant des métriques comme la précision, le rappel ou le F1-score

La Distribution Gaussienne Multivariée

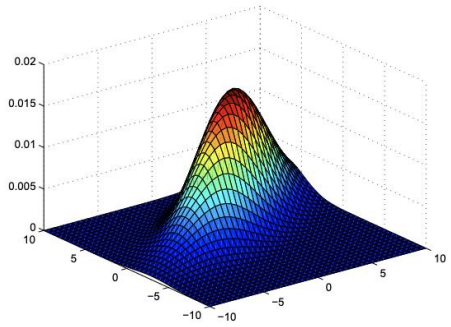
Conclusion

- La Distribution Gaussienne Multivariée est efficace lorsque les variables sont **corrélées**.
- Elle suppose que les données suivent la même **distribution gaussienne de moyenne μ et de matrice de variance covariance Σ**. Si ce n'est pas le cas, les données doivent être transformées ou changer l'approche.
- Le choix du **seuil** est crucial et peut être ajusté en fonction de la sensibilité souhaitée du détecteur d'anomalies.

Modèle de Mélange Gaussien

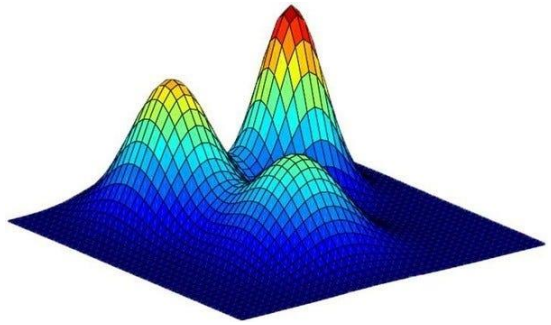
(Gaussian Mixture Model :GMM)

- Un vecteur aléatoire $X = (X_1, X_2, \dots, X_n)^T$ suit une distribution gaussienne multivariée si sa fonction de densité de probabilité (PDF) est donnée par:



$$N(x; \mu; \Sigma) = \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

- Contrairement à la distribution gaussienne multivariée qui suppose que les données provient d'un seul cluster avec une seule distribution gaussienne multivariée, **le modèle de mélange gaussien (GMM)** suppose que les données proviennent de plusieurs clusters chacun avec sa propre distribution gaussienne multivariée



Modèle de Mélange Gaussien

(Gaussian Mixture Model :GMM)

- Un GMM combine plusieurs distributions gaussiennes pour modéliser des données complexes.
- La densité de probabilité d'un GMM est une somme pondérée de K distributions gaussiennes :

$$p(x|\theta) = \sum_{k=1}^{K} \pi_k \, N(x; \mu_k; \Sigma_k)$$

Où :

- π_k est le poids de la k-ième composante gaussienne, avec $\sum_{k=1}^{K} \pi_k = 1$ et $\pi_k \geq 0$
- μ_k est al moyenne de la k-ième composante
- Σ_k est la matrice de variance-covariance de la k-ième composante
- $N(x; \mu_k; \Sigma_k) = \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma_k|^{\frac{1}{2}}} \exp(-\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)$
- $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^{K}$ sont les paramètres du modèle

Modèle de Mélange Gaussien: Estimation des paramètres

- Les paramètres du modèle sont estimés par l'algorithme **Expectation-Maximization (EM), c'est une** méthode itérative pour estimer les paramètres d'un modèle probabiliste lorsque certaines variables sont latentes (non observées).

Objectif:

Maximiser la log-vraissemblance des données observées:

$$\lin\big(p(X,\theta)\big) = \sum_{i=1}^{n} \lin\left(\sum_{k=1}^{K} \boldsymbol{\pi_k}\, \boldsymbol{N}(\boldsymbol{x_i}; \boldsymbol{\mu_k}; \boldsymbol{\Sigma_k})\right)$$

- Une fois les paramètres du modèles sont estimés (fonction densité), les points avec une probabilité inférieure à une valeur seuil (à choisir) seront considérés comme anomalies

GMM comme un algorithme de clustering

Remarque 1:

- MMG peut servir également comme un algorithme de clustering, une fois l'algorithme EM convergé, on peut attribuer chaque point x_i au cluster pour lequel il a la plus grande probabilité d'appartenance :

$$cluster\ (i) = argmax_k \gamma_{ik}$$

- γ_{ik} est la probabilité que la ligne i appartient au cluster $k \in \{1, \dots, K\}$, elle est obtenue à la fin de l'algorithme EM.
- Contrairement à K-means, GMM fournit des probabilités d'appartenance aux clusters, ce qui permet une interprétation plus fine et une meilleure robustesse au bruit.

GMM comme un algorithme de:
« features extraction »

Remarque 2:

- MMG peut servir également comme une technique d'extraction de nouvelles variables ($features\ extraction$):
- La probabilité a posteriori γ_{ik} (responsabilité) mesure le degré d'appartenance de l'observation x_i à la composante gaussienne k.
- Ces probabilités peuvent être utilisées comme caractéristiques pour représenter les données dans un nouvel espace de dimension K(où K est le nombre de composantes)

Exemple :

Si $K = 3$, chaque point x_i est représenté par un vecteur de 3 dimensions :

$$\boldsymbol{Fi} = [\gamma_{i1}, \gamma_{i2}, \gamma_{i3}]$$

Ces caractéristiques peuvent ensuite être utilisées pour des tâches de classification ou de clustering.

Introduction à l’IA générative