PROJET MACHINE LEARNING & STATISTIQUE (ECC)

Sujet 11 : Système Multi-Agents & Méthodes MCDM pour la Sélection de Candidats

Feuille de Route & Synthèse Finale des Travaux Réalisés

1. Source & Données Brutes (Kaggle / UC Berkeley Haas)

- **Jeu de données :** *Predicting Hiring Decisions in Recruitment Data* (Auteur : Rabie El Kharoua).
- **Lien public :** https://www.kaggle.com/datasets/rabieelkharoua/predicting-hiring-decisions-in-recruitment-data
- **Volumétrie :** 1 500 candidats réels, 11 variables, 0 valeur manquante (enregistré dans data/raw/).

2. EDA & Découpage Three-Way Holdout (Anti-Fuite de Données) [FAIT ■]

- **Déséquilibre de classe :** 31% embauchés (465) vs 69% rejetés (1 035) $\rightarrow$ justifie l'emploi de SMOTE.
- **Three-Way Holdout (Cours 1, slides 84-86) :** Découpage strict AVANT pré-traitement : Train (70% - 1 049), Val (15% - 226), Test (15% - 225).
- **Figures produites (4) :** Enregistrées dans reports/figures/fig1_ à fig4_.

3. Analyse Factorielle (ACP) & Clustering Non Supervisé (Cours 2) [FAIT ■]

- **ACP 2D (Cours 2, slides 17-37) :** PC1 capture l'excellence technique (+0.55 *SkillScore*) ; PC2 capture la maturité relationnelle (+0.54 *PersonalityScore*, +0.46 *Age*).
- **Validation du nombre de clusters :** Test de $k=2$ à $k=6$, optimal à $k=2$ validé par le **Score de Silhouette** (slide 68).
- **Figures produites (3) :** fig5_clustering_evaluation.png, fig6_pca_clusters_projection.png, fig7_clusters_archetypes_profile.png.

4. Machine Learning Supervisé, SMOTE & Explicabilité SHAP (Cours 1) [FAIT ■]

- **Traitement du déséquilibre (Cours 1, slides 57-59) :** SMOTE appliqué **uniquement** sur Train (équilibrage 724/724).
- **Performances sur Test :** Random Forest atteint **91.1% d'Accuracy**, **85.7% de Précision/Rappel** et **ROC-AUC = 0.921** (surpassant la Baseline logistique à 82.7%).
- **Explicabilité SHAP (slides 51-54) :** Importance globale dominée par *InterviewScore* et *SkillScore* ; cascades locales individuelles (waterfall).
- **Figures produites (6) :** fig8_ à fig13_.

5. Système Multi-Agents & Moteur Décisionnel MCDM (Sujet 11) [FAIT ■]

- **Comité d'Évaluation :** Délibération simultanée de 4 agents (Lead Tech, RH & Fit, Expérience & Séniorité, Éthique & Équité).
- **Pondération AHP (Saaty) :** Dérivation des poids : Technique (46.6%), Expérience (27.7%), RH (16.1%), Éthique (9.6%).
- **Validation de cohérence :** Ratio de cohérence **$CR = 0.0115 < 0.10$** (Jugement mathématiquement rigoureux et cohérent).
- **Confrontation Baseline WSM vs TOPSIS :** $\rho = 0.895$. TOPSIS réajuste 94.7% des rangs en pénalisant les profils déséquilibrés et en récompensant la proximité géométrique avec le profil idéal.
- **Analyse de Sensibilité :** Stabilité prouvée du Top 5 lors de variations de pondération technique de -30% à +30%.
- **Figures produites (4) :** fig14_ à fig17_.

6. Déploiement Interactif & Démonstration Web (Streamlit) [FAIT ■]

- **Application opérationnelle (app/app_streamlit.py) :** Hébergée en local à http://localhost:8501.
- **Onglet 1 (Classement MCDM) :** Tableau interactif filtrable par genre/scores avec téléchargement CSV.
- **Onglet 2 (Fiche Candidat) :** Délibérations textuelles complètes des 4 agents + radar de compétences.
- **Onglet 3 (Simulateur Direct) :** Formulaire interactif pour évaluer instantanément un nouveau profil avec calcul TOPSIS et probabilité ML.
- **Onglets 4 & 5 (XAI & ACP) :** Galerie interactive des graphiques factoriels ACP et d'explicabilité SHAP.